

ADVISOR BRIEF

ElicitAlign-Bench | 汇报精简版

15-20 分钟讲清新方向、最近邻风险和最小实验

导师汇报 · 组会讲解 · 决策讨论

文档版本	v0.45 · 汇报精简版
日期	2026 年 8 月 12 日
研究主线	自然输入 → 自主发现 → 澄清 → 交付 → 否决门

核心命题

PDR-Bench 问 persona 给出后会不会用；ElicitAlign-Bench 问没有 persona 和提醒时会不会自己找出来并用对。

内容导航

1. 大框架
2. 四条件能力分解
3. Case 和 metadata
4. 主条件与筛题原则
5. 评分
6. 最近邻压力
7. 最小实验
8. 八周与决策

建议讲法：2 分钟问题、4 分钟数据、4 分钟实验与指标、3 分钟 Judge、3 分钟风险和导师决策。

研究概要

一句话： 用户没把关键个性化信息说全时，agent 会不会在没有提醒的情况下自己发现、问对、问够，然后把答案真正落实到 Deep Research 交付物？

这不是简单的 when-to-ask。IDRBench、IntentRL、DiscoBench 和最新 G-STEER 已覆盖交互、主动澄清、搜索歧义和个性化研究 Ask/Stop。[1](#)[2](#)[3](#)[4](#) 新方向能否成立，取决于它是否用“无 persona、无提醒、paired real users、完整 persona oracle、充分信息负对照和最终利用追踪”发现已有指标看不到的系统差异。

ElicitAlign-Bench: 一张图讲完评测流程




图1 从隐藏 user ledger 和自然欠指定输入, 到四条件能力分解、交付评分与论文生死门。

1. 大框架

输入不是完整 persona，而是一个足够生成通用报告、却缺少 1-3 个决策相关用户条件的自然 instruction。隐藏真值是 user-state ledger。Agent 可以直接执行，也可以主动问。用户回答后，agent 继续搜索并交付报告。

Benchmark 不只看问题好不好，而追踪：

发现缺口 → 提问 → 获得事实 → 知道何时停止 → 用进计划 → 改变最终建议

2. 四条件能力分解

条件	测什么
Natural-Interactive	没提醒时会不会自主问
Nudge-Interactive	被提醒后是否具备执行能力
No-Ask	不问时的通用回答下限
Full-Persona Oracle	信息全给时的表现上限

Natural-No-Ask 是自主询问收益；Nudge-Natural 是主动触发缺口；Oracle-Natural 是剩余信息恢复与利用缺口。四个绝对分必须同时报告，不能只看差值。

3. Case 和 metadata

每个 family 固定 task/evidence/tools/budget/output，配对两位只在 2-4 个关键决策条件上不同的用户。Case 包括：case metadata、task metadata、隐藏 user ledger、欠指定记录、must-change/must-hold/must-not contracts、环境与运行版本。Formal 数据首选真实用户。LLM persona 只跑 smoke test。研究构念双人标注仲裁，pilot 结果不能反改任务标签。

4. 为什么主条件不提醒，也不筛“都会问”的题

提醒会把主动发现变成 prompt compliance，所以只放在 Nudge 诊断条件。按模型是否会问来筛题会造成选择偏差。任务必须先由人类决策逻辑冻结，并包含 obvious critical、subtle critical、sufficient、irrelevant-missing 四类。

5. 评分

轨迹层：Need Detection、Elicitation Recall、Question Precision、Information Gain/Turn、Stopping、Burden、Privacy/Permission。交付层：Absolute Adequacy、must-change/must-hold/must-not、共同质量、事实可靠性、目标用户效用。利用链：asked → answered → plan → report → changed decision。
只有需要时间、不需要时不问；Natural 比 No-Ask 有收益；绝对质量合格；共同质量无伤害；无边界违规；且事实真的改变交付，才算成功。

6. 最近邻压力

最危险 reviewer 评价：“这是 G-STEER 的 benchmark 化。”

必须用结果回答，而不是靠措辞：

- Natural 与 Full-Persona 是否造成模型排名重排？
- 是否有系统问得好但用不好？
- sufficient controls 是否揭示高分系统过问或触碰敏感信息？
- paired real-user contracts 是否发现 P/Q 或 target coverage 看不到的错误？

若都没有，停止这个方向。

7. 最小实验

3 family：团队知识库采购、国际家庭旅行、研究工具选型。每个 family 两位用户、四类 case、四条件、4-6 个系统。LLM 先造任务/persona，由研究者逐条确认自然性与决策影响。

继续门：至少两个 family 出现四条件分离；至少一个系统发生 Oracle/Natural 排名变化或稳定 utilization failure；充分任务不过问；人工评分一致；成本可扩展至 24 family。

8. 八周与决策

第 1-2 周跑 novelty-kill pilot；第 3 周决定继续/收窄/换题；第 4-5 周建 24 family；第 6 周主实验和真人重放；第 7 周校准与近邻对照；第 8 周论文与复现包。

当前建议：可以做最小实验，但还不应承诺这是最终 ICLR 题目。先让它通过 G-STEER / IDR Bench 正面对照和排名重排门。

参考文献

[1] [IDRBench](#) · [2] [IntentRL](#) · [3] [DiscoBench](#) · [4] [G-STEER](#) · [5] [PDR-Bench](#)

AI 辅助说明

AI 工具用于检索、结构化与排版；研究真值和结论需人工核验。