

CONDENSED RESEARCH PROPOSAL

# ElicitAlign-Bench

## 从缺失用户信息到个性化交付

正式论文 Proposal 精简版 · 约 10 页

|      |                                                    |
|------|----------------------------------------------------|
| 文档版本 | v0.45 · 正式精简版                                      |
| 日期   | 2026 年 8 月 12 日                                    |
| 研究主线 | Natural · Nudge · No-Ask · Oracle · Final Delivery |

核心命题

不提醒 agent 先澄清，测它是否自主发现、问对、停对并把用户回答真正落实到最终交付。

## 摘要

现有个性化 Deep Research benchmark 多在 persona 或用户上下文已经给出的情况下评价报告。现实用户却常漏掉预算、风险、使用情境或决策标准。问题因此不只是“模型会不会使用 persona”，还包括：它是否会在没有提醒时意识到缺了哪些会改变答案的用户信息，提出必要问题，知道何时停止，并把回答落实到最终交付物。

这一问题已有强近邻。IDRBench 测 interactive Deep Research 的收益与成本；IntentRL 训练主动澄清；DiscoBench 测深度搜索中的歧义发现和路径恢复；G-STEER 已直接研究个性化 Deep Research 的 Retrieve/Ask/Stop 与下游报告质量。[1234](#) 因此 ElicitAlign-Bench 不声称首次研究 clarification，而测试一个更窄、仍待实证证明的新问题：**在没有显式 persona、没有澄清提醒、任务仍可被泛化执行时，通用 agent 能否自主恢复决策相关用户状态，并把它正确用于最终个性化交付。**

Benchmark 以 paired user task family 为单位，设置 Natural-Interactive、Nudge-Interactive、No-Ask 和 Full-Persona Oracle 四条件，并加入信息充分与无关缺失负对照。主结果不是单一差值，而是 need detection、targeted elicitation、stopping、utilization、最终效用、共同质量、负担和边界组成的非补偿 profile。若 pilot 不能产生 Natural/Oracle 排名重排或 G-STEER/IDRBench 未覆盖的诊断，本方向停止。

## ElicitAlign-Bench 端到端研究设计

## ElicitAlign-Bench: 从缺失用户信息到个性化交付

无显式 persona、无澄清提醒的自然输入 → 自主发现 → 精准提问 → 充分停止 → 最终交付利用; 完整 persona 仅作 oracle ceiling

主张必须通过 G-STEER / IDRBench 否决门

## 1 真实任务与隐藏真值

## Task family: 共同任务不变

固定 task shell · evidence snapshot · tools · budget  
固定 deliverable · common fact core · success conditions

## Case metadata

case / family / user ID  
来源 · 语言 · 领域 · stakes  
构建/审核/冻结时间  
环境与版本 provenance  
客观字段自动导入, 人工抽查

## Task metadata

research intent · context  
deliverable · evidence need  
freshness · fan-out · tools  
共同事实与可接受答案空间  
研究概念双人独立标注 + 仲裁

## Hidden user-state ledger (主实验不可见)

字段值 · 证据来源 · participant verified · 稳定性  
decision relevance · affects decision nodes · sensitivity  
directly askable? · history inferable? · permission  
只保留 2-4 个会改变决定的用户轴, 不写冗长人格故事

## 欠指定记录 + 三类 contracts

删除字段: critical obvious / subtle / irrelevant / none  
must-change: 知道差异后哪些建议必须变  
must-hold: 共同事实、证据和格式不应变  
must-not: 不得猜测、越权询问或被露

## 2 自然欠指定实例构造

完整任务  $q^*$  → 自然输入  $q$ 只删除 1-3 个 decision-changing user fields  
保留共同任务、交付格式与通用可执行性

## 四类 case type (都要有)

Critical · obvious

Critical · subtle

Sufficient · 不该问

Irrelevant missing

## 自然性与可识别性 gate

- ① 不问也能生成貌似合理的通用报告
- ② 问到后确实改变至少一个 decision node
- ③ 问题可由用户自然回答, 且不泄露答案

## 数据来源优先级

真实用户共享 task shell (最佳)  
真人 + 最小反事实用户 (需第二人验证)  
纯 LLM 用户: 只做 smoke test, 不进正式真值  
禁止按 "pilot 中模型是否询问" 反向筛选

## 3 四条件 × 交互澄清循环

## C0 Natural

 $q$ : 可问用户  
不出现 persona / clarify 提醒  
主条件: 自主发现

## C1 Nudge

 $q$ : 可问用户  
提醒 "必要时可澄清"  
诊断: 被提示后的能力

## C2 No-Ask

同一  $q$ : 禁用用户沟通  
直接完成研究与报告  
通用回答下限

## C3 Oracle

 $q^*$  + 完整相关 ledger  
无需再问, 但仍独立评分  
完整 persona ceiling

## Natural / Nudge 的可重放交互循环

思 → 问 → 答 → 停

每轮记录 node: unknown → asked → answered → planned  
模拟器只答被问内容; 不主动泄露、不提示下一问  
停止成功 = 剩余不确定性不足以改变可接受建议, 而非问满轮数

## 统一执行控制

same backbone · tools · evidence · budget · output · seeds

## 4 Deep Research 执行

## 计划 / 查询形成

用户事实是否改变 research scope?

## 检索 / 浏览 / 证据整合

搜索与证据优先级是否真正改变?

## 比较 / 选择 / 风险处理

硬约束与用户标准是否进入决策?

## 最终长报告 / 交付物

must-change 是否发生?  
must-hold 与事实质量是否保持?

## 长程利用失败定位

问到但未进入计划  
计划中有, 执行/子 agent 丢失  
报告复述用户, 却未改变建议  
事实每经过一层都要 event trace

## 5 非补偿评分

## A | Clarification trajectory

Need Detection: 该问 / 不该问  
Recall / Precision / Info Gain  
Stopping sufficiency  
Burden: turn / token / time / repeat  
Privacy / permission boundary  
不能靠 "多问" 刷 coverage

## B | Final delivery

Absolute Adequacy (先绝对合格)  
must-change / hold / not  
Common Quality non-inferiority  
Factual Reliability  
Target-user Utility  
Oracle 也不是参考答案, 同样评分

## 三个效应 + 原始四臂

SelfInitiated =  $U0 - U2$   
NudgeGap =  $U1 - U0$   
OracleGap =  $U3 - U0$   
差值大但  $U0$  不合格 ≠ 成功  
OracleRecovery 仅作次级描述  
family-blocked permutation + cluster bootstrap

## 6 Benchmark 能回答哪些系统差异?

## ① 会用 persona ≠ 会自己找

Oracle 高、Natural 低  
说明显式条件掩盖部署失败  
Natural / Oracle 排名是否重排?  
对 PDR-Bench 的核心增量检验

## ② 没意识到 vs 不会做

Nudge - Natural 大:  
能力可被提示唤起, 但不自主  
Nudge 仍低: 提问/停止本身弱  
给 agent 设计提供直接诊断

## ③ 会问 ≠ 会用

关键事实已 answered  
但 plan/report/decision 未改变  
暴露长程传递与利用失败  
不能被 question quality 单独看到

## ④ 少问不一定好, 多问也不等于好

Critical recall × Sufficient specificity  
结合 burden 与 sensitive boundary  
测 "最小充分信息", 不是问题数量  
过问与隐私成本是独立失败

## 主榜不是单一总分: 能力画像 + 非补偿五门

需要时间且充分时不问 · Natural 相比 No-Ask 有收益 · Natural 绝对合格 · 共同质量/事实无伤害 · 无权限/隐私违规且 must-change 真正发生  
统计单位 = task family; 同 family 的用户、条件和 seeds 不是独立样本。报告 family-level paired effect、CI、分布与失败案例。  
结论边界: 只主张 "自主用户状态发现与利用行为", 不主张模型内部真正理解或关心用户。

## 7 Novelty-kill pilot 与论文生死门

## 最小矩阵

3 family × 2 users × 4 case types × 4 conditions × 4-6 systems  
LLM 造 shell/persona 后必须由研究者逐条验证

## 继续扩到 24 family, 如果:

- ✓  $\geq 2$  family 四条件有意义分离
- ✓  $\geq 1$  稳定 Oracle/Natural 排名重排
- ✓ 或出现 "问到但未利用" 独立失败
- ✓ sufficient controls 不被普遍过问
- ✓ 人工 contract 一致、成本可承受
- 再做  $\geq 20\%$  真人重放与 simulator 校准

## 停止 / 换题, 如果:

- × 一句 Nudge 让所有系统接近 Oracle
- × G-STEER / IDRBench 已完全解释排名
- × 真人与 simulator 反转核心结论
- × 差异只由长度/预算/通用能力造成
- × 用户无法就 decision nodes 达成一致
- 最危险评价: "G-STEER 的 benchmark 化"

图 1 自然欠指定输入经四条件交互与 Deep Research 执行后, 以轨迹和最终交付的非补偿 profile 评价。

1. 核心研究问题

- 在自然欠指定 instruction 下，agent 会不会自行发起必要澄清？
- 它问的是会改变最终决策的变量，还是无关人物背景？
- 关键变量解决后能否停止，并在任务充分时避免过问？
- 用户回答是否真正改变搜索、比较标准和最终建议？
- Full-Persona、Nudge 与 Natural 条件是否给出不同系统排名？

可观察主张仅限于“自主用户状态发现与利用行为”，不推断模型真正关心或理解用户。

2. Case、Task 与用户真值

一个 task family 固定共同任务、证据、工具、预算与交付格式，配对两位在 2-4 个决策相关变量上不同的用户。首选真实参与者提供 task shell 和 user-state；最小反事实用户必须由第二位目标人群参与者验证。纯 LLM persona 只用于 smoke test。

每个 case 包含：

- Case metadata：** family、来源、版本、领域、风险、审核和冻结记录；
- Task metadata：** research intent、使用情境、交付物、证据依赖、时效性、工具预算、共同事实核心；
- Hidden user-state ledger：** 字段值、来源、敏感度、可询问性、决策相关性和影响节点；
- Underspecification metadata：** 删除了什么、critical/irrelevant/none、可由什么问题恢复；
- Evaluation contracts：** must-change、must-hold、must-not。

研究构念由两名标注员独立标注并仲裁。LLM 可预填但不是真值。运行后难度和失败类型另存，不能反改预先标签。

3. 四条件实验

| 条件                     | 输入与交互                        | 识别目标       |
|------------------------|------------------------------|------------|
| C0 Natural-Interactive | 欠指定自然 instruction；可问；无任何澄清提醒 | 自主发现与行动    |
| C1 Nudge-Interactive   | 同一 instruction；提醒“必要时可澄清”    | 被提示后的可执行能力 |
| C2 No-Ask              | 同一 instruction；禁止询问          | 通用回答下限     |
| C3 Full-Persona Oracle | 提供完整、已验证的相关 ledger           | 已知用户信息时的上限 |

主比较 C0-C2 测自主交互收益；C1-C0 测自主触发缺口；C3-C0 测距离完整 persona 上限的缺口。C3 不是参考答案，仍须接受同一事实、质量和用户适配评分。

正式集不能只选“多数模型明显会问”的任务，否则会按模型行为筛题。数据先按人类决策逻辑冻结，并同时覆盖 obvious critical、subtle critical、sufficient 和 irrelevant-missing。

## 4. 交互与用户模拟

用户模拟器读取隐藏 ledger，但只回答 agent 实际询问的内容，不主动泄露、不给下一问题提示、不复制 rubric。每个问题映射到 ledger node，并记录回答是否完整、拒绝或需要重述。

至少 20% case 由真实用户重放，比较模拟器与本人回答一致率、问题自然性/必要性以及系统排序。若真人与模拟器导致相反结论，模拟主榜降为开发诊断。

## 5. 评分与统计

### 5.1 轨迹层

- Need Detection sensitivity / specificity / macro-F1 ;
- 关键节点 Elicitation Recall 与 Question Precision ;
- 每轮解决的加权决策节点 ;
- 停止时是否仍有会改变建议的 unresolved node ;
- 轮数、用户 token、重复、等待时间 ;
- 敏感提问、越权推断和拒答后追问违规。

### 5.2 交付层

- Absolute Adequacy ;
- must-change / must-hold / must-not compliance ;
- common quality 与 factual reliability non-inferiority ;
- 目标用户效用与硬约束违规 ;
- asked → answered → plan → report → changed decision 的逐节点 utilization trace。

### 5.3 效应

```
SelfInitiatedGain = U_Natural - U_NoAsk
NudgeGap          = U_Nudge - U_Natural
OracleGap          = U_Oracle - U_Natural
```

所有差值必须与四个 arm 的绝对分同时报告。Natural 未通过 adequacy 时，不能因 No-Ask 更差而宣称成功。

OracleRecovery 只作次级描述，且仅在  $U_{\text{Oracle}} - U_{\text{NoAsk}} > \epsilon$  时计算。

同一 family 内的用户、条件和随机种子相关；统计单位为 family。主分析使用 family-blocked permutation 与 family-cluster bootstrap，报告 family-level paired effects 和分布。

## 6. 最近邻与真正的论文风险

PDR-Bench 已解决显式 persona 条件下的报告适配；IDRBench 已解决交互 DR 的收益/成本；IntentRL 与 DiscoBench 已解决主动澄清的重要部分；G-STEER 与本方向最接近，甚至已把 personalized framing factor、Ask/Stop、问题负担和下游 P/Q 连在一起。<sup>5</sup>

因此最大审稿风险是“G-STEER 的 benchmark 化”。防守不能靠换名，而要靠四类实证证据：

1. 无静态 profile、无提醒的 natural condition 暴露不同能力；
2. paired real-user ledger 与 contracts 能证明问题答案应如何改变最终交付；
3. sufficient controls 揭示过问与隐私成本；
4. Full-Persona 与 Natural 发生稳定排名重排，或出现“会问但不会用”的独立失败。

如果这些结果不出现，就不应把本方向包装成独立 ICLR benchmark。

## 7. Pilot、规模与成功门

Pilot 使用 3 个 family（知识库采购、国际家庭旅行、研究工具选型），4-6 个系统，四条件和四类 case。LLM 先生成任务与用户，再由研究者逐条验证自然性、决策影响、可询问性和无泄漏。

继续扩到 24 family 的条件：至少两个 family 出现四条件有意义分离；至少一个模型发生 Full-Persona/Natural 排名变化或稳定 utilization failure；充分任务不过问；人工 contract 评分一致；成本可承受。

单个系统只有同时通过以下五门，才算成功：需要时间、不需要时不问；Natural 比 No-Ask 有真实收益；Natural 达到绝对 adequacy；共同质量无伤害；无隐私/权限违规且获取信息确实改变了应改变的节点。

## 8. 八周计划与预期贡献

第 1-2 周完成 3-family novelty-kill pilot；第 3 周作继续/停止决策；第 4-5 周扩建并冻结 24 family；第 6 周主实验和真人重放；第 7 周 judge 校准、消融和近邻对照；第 8 周论文与复现包。

若通过，贡献是：自然欠指定的 paired-user benchmark；Natural/Nudge/No-Ask/Oracle 四条件能力分解；从问题到最终交付物的可追溯非补偿评价。不能声称首次 clarification、首次 interactive DR 或模型真正理解用户。

## 参考文献

- [1] IDRBench. 2026.
- [2] IntentRL. 2026.
- [3] DiscoBench. 2026.
- [4] G-STEER. 2026.
- [5] PDR-Bench. ICLR 2026.
- [6] Ask Early, Ask Late, Ask Right. 2026.
- [7] Ask-before-Plan. 2024.
- [8] Tell Me More!. 2024.

## AI 辅助说明

AI 工具用于文献检索、结构化和文档生成。正式数据中的用户状态、研究构念、rubric 和评分必须由作者与参与者核验。