

RESEARCH PROPOSAL

ElicitAlign-Bench

从缺失用户信息到个性化交付

Interactive Agents · Personalization · Deep Research

文档版本	v0.45 · 方向否决版
日期	2026 年 8 月 12 日
研究主线	Detect · Elicit · Stop · Use · Deliver

核心命题

不给显式 persona 和澄清提醒，测 agent 是否自主恢复决策相关用户状态，并用完整 persona oracle 验证信息是否真正进入最终交付。

内容导航

1. 研究问题与可证伪假设
2. Case、Task 与隐藏用户真值
3. 四条件实验与交互协议
4. 非补偿评分与统计
5. 最近邻边界与 Novelty-kill gate
6. 工程实现与最小实验
7. 八周计划、贡献与主张边界
8. 参考文献

阅读提示：先看主图与第 1-4 节理解任务原语；第 6-8 节解释指标、统计和最近邻边界；第 10 节是本方向继续或停止的硬门。

研究概要

现实用户通常不会先写好一张完整 persona 再交给 agent。他们更可能只说“帮我调研一个适合我的方案”，却漏掉预算、风险容忍度、使用情境、已有资源或真正的决策标准。此时，一个 agent 即使在“完整 persona 已给出”时能生成很好的个性化报告，也不代表它在真实使用中会意识到缺了什么、主动询问、在合适的时候停止，并把得到的信息落实到最终交付物。

ElicitAlign-Bench 评测这条完整链条：发现缺失的决策相关用户信息 → 提出必要且合适的问题 → 判断何时信息已经足够 → 将回答正确用于研究计划和最终报告。主实验不给 agent 任何“请先澄清”或“请考虑个性化”的提醒；提醒只作为诊断条件，用来区分“没有主动意识到”与“知道应该问但执行不好”。

这个方向不能声称“首次研究欠指定任务中的 clarification”。IDRBench 已比较 Deep Research 的 autonomous 与 interactive 条件；IntentRL 已训练主动澄清潜在意图；DiscoBench 已评测搜索 agent 的歧义发现、提问和路径恢复；G-STEER 更直接地研究个性化 Deep Research 中的 Retrieve / Ask / Stop 与下游报告个性化。[1](#)[2](#)[3](#)[4](#) 因此，本项目的可辩护增量必须收窄为：在没有显式 persona、没有澄清提醒、但任务仍可被泛化执行的自然输入下，测量通用 agent 自主恢复用户特异性所需信息的能力，并用完整 persona oracle 和成对用户反事实检验这些信息是否真正改变了最终交付物。

本 proposal 把这一主张设为待证假设，而不是既定事实。若最小实验不能发现 Natural 与 Nudge 的稳定差异、不能发现“会用完整 persona”与“会自己问出来”的模型重排，或不能产生 G-STEER / IDRBench 未覆盖的诊断结论，则停止该方向，不扩建正式 benchmark。

ElicitAlign-Bench 端到端研究框架

ElicitAlign-Bench: 从缺失用户信息到个性化交付

无显式 persona、无澄清提醒的自然输入 → 自主发现 → 精准提问 → 充分停止 → 最终交付利用; 完整 persona 仅作 oracle ceiling

主张必须通过 G-STEER / IDRBench 否决门

1 真实任务与隐藏真值

Task family: 共同任务不变

固定 task shell · evidence snapshot · tools · budget
固定 deliverable · common fact core · success conditions

Case metadata

case / family / user ID
来源 · 语言 · 领域 · stakes
构建/审核/冻结时间
环境与版本 provenance
客观字段自动导入, 人工抽查

Task metadata

research intent · context
deliverable · evidence need
freshness · fan-out · tools
共同事实与可接受答案空间
研究构思双人独立标注 + 仲裁

Hidden user-state ledger (主实验不可见)

字段值 · 证据来源 · participant verified · 稳定性
decision relevance · affects decision nodes · sensitivity
directly askable? · history inferable? · permission
只保留 2-4 个会改变决定的用户轴, 不写冗长人格故事

欠指定记录 + 三类 contracts

删除字段: critical obvious / subtle / irrelevant / none
must-change: 知道差异后哪些建议必须变
must-hold: 共同事实、证据和格式不应变
must-not: 不得猜测、越权询问或披露

2 自然欠指定实例构造

完整任务 q^* → 自然输入 q 只删除 1-3 个 decision-changing user fields
保留共同任务、交付格式与通用可执行性

四类 case type (都要有)

Critical · obvious

Critical · subtle

Sufficient · 不该问

Irrelevant missing

自然性与可识别性 gate

- ① 不问也能生成貌似合理的通用报告
- ② 问到底确实改变至少一个 decision node
- ③ 问题可由用户自然回答, 且不泄露答案

数据来源优先级

真实用户共享 task shell (最佳)
真人 + 最小反事实用户 (需第二人验证)
纯 LLM 用户: 只做 smoke test, 不进正式真值
禁止按 "pilot 中模型是否合用" 反向筛选

3 四条件 × 交互澄清循环

C0 Natural

q: 可问用户
不出现 persona / clarify 提醒
主条件: 自主发现

C1 Nudge

q: 可问用户
提醒 "必要时可澄清"
诊断: 被提示后的能力

C2 No-Ask

同一 q: 禁用用户通道
直接完成研究与报告
通用回答下限

C3 Oracle

q: 完整相关 ledger
无需再问, 但仍独立评分
完整 persona ceiling

Natural / Nudge 的可重放交互循环

宣 → 问 → 答 → 停

每轮记录 node: unknown → asked → answered → planned
模拟器只答被问内容; 不主动泄露、不提示下一问
停止成功 = 剩余不确定性不足以改变可接受建议, 而非问满轮数

统一执行控制

same backbone · tools · evidence · budget · output · seeds

4 Deep Research 执行

计划 / 查询形成

用户事实是否改变 research scope?

检索 / 浏览 / 证据整合

搜索与证据优先级是否真正改变?

比较 / 选择 / 风险处理

硬约束与用户标准是否进入决策?

最终长报告 / 交付物

must-change 是否发生?
must-hold 与事实质量是否保持?

长程利用失败定位

问到但未进入计划
计划中有, 执行/子 agent 丢失
报告复述用户, 却未改变建议
事实每经过一层都留 event trace

5 非补偿评分

A | Clarification trajectory

Need Detection: 该问 / 不该问
Recall / Precision / Info Gain
Stopping sufficiency
Burden: turn / token / time / repeat
Privacy / permission boundary
不能靠 "多问" 刷 coverage

B | Final delivery

Absolute Adequacy (先绝对合格)
must-change / hold / not
Common Quality non-inferiority
Factual Reliability
Target-user Utility
Oracle 也不是参考答案, 同样评分

三个效应 + 原始四臂

SelfInitiated = $U0 - U2$
NudgeGap = $U1 - U0$
OracleGap = $U3 - U0$
差值大但 $U0$ 不合格 ≠ 成功
OracleRecovery 仅作次级描述
family-blocked permutation + cluster bootstrap

6 Benchmark 能回答哪些系统差异?

① 会用 persona ≠ 会自己找

Oracle 高、Natural 低
说明显式条件掩盖部署失败
Natural / Oracle 排名是否重排?
对 PDR-Bench 的标心增量检验

② 没意识到 vs 不会做

Nudge - Natural 大:
能力可被提示唤起, 但不自主
Nudge 仍低: 提问/停止本身弱
给 agent 设计提供直接诊断

③ 会问 ≠ 会用

关键事实已 answered
但 plan/report/decision 未改变
暴露长程传递与利用失败
不能被 question quality 单独看到

④ 少问不一定好, 多问也不等于好

Critical recall × Sufficient specificity
结合 burden 与 sensitive boundary
测 "最小充分信息", 不是问题数量
过问与隐私成本是独立失败

主榜不是单一总分: 能力画像 + 非补偿五门

需要时间且充分时不问 · Natural 相比 No-Ask 有收益 · Natural 绝对合格 · 共同质量/事实无伤害 · 无权限/隐私违规且 must-change 真正发生
统计单位 = task family; 同 family 的用户、条件和 seeds 不是独立样本。报告 family-level paired effect, CI、分布与失败案例。
结论边界: 只主张 "自主用户状态发现与利用行为", 不主张模型内部真正理解或关心用户。

7 Novelty-kill pilot 与论文生死门

最小矩阵

3 family × 2 users × 4 case types × 4 conditions × 4-6 systems
LLM 造 shell/persona 后必须由研究者逐条验证

继续扩到 24 family, 如果:

- ✓ ≥ 2 family 四条件有意义分离
 - ✓ ≥ 1 稳定 Oracle/Natural 排名重排
 - ✓ 或出现 "问到但未利用" 独立失败
 - ✓ sufficient controls 不被普遍过问
 - ✓ 人工 contract 一致、成本可承受
- 再做 > 20% 真人量数与 simulator 校准

停止 / 换题, 如果:

- × 一句 Nudge 让所有系统接近 Oracle
 - × G-STEER / IDRBench 已完全解释排名
 - × 真人与 simulator 反转核心结论
 - × 差异只由长度/预算/通用能力造成
 - × 用户无法就 decision nodes 达成一致
- 最危险评价: "G-STEER 的 benchmark 化"

图 1 从 task/case metadata、隐藏 user ledger 与自然欠指定输入, 到四条件交互、最终交付评分、系统能力分解和论文否决门。

1. 研究问题为什么值得单独测

1.1 完整 persona 条件会隐藏真实部署中的第一道失败

PDR-Bench 给 agent 结构化 persona 与动态上下文，再评价最终报告的 Personalization、Quality 与 Reliability。[5](#) 这种设置能回答“当用户条件已经提供时，系统能否利用它们”，但不能单独回答“系统是否会发现关键用户条件根本没有被说出来”。两种能力可能完全不同：

- 系统 A 在完整 persona 下表现很好，却在自然输入下直接猜测预算和风险偏好；
- 系统 B 会提出一个准确问题，但得到回答后没有修改检索或建议；
- 系统 C 不停提问，获得大量人物信息，却没有增加最终决策价值；
- 系统 D 在任务已经充分说明时仍然追问，增加负担或触碰不必要的敏感信息。

只评最终 persona-conditioned 报告会把这些失败压在同一个结果里；只评问题质量又无法证明提问真的帮助了交付。

1.2 本项目测的不是一般语言歧义，而是“决策相关用户状态缺口”

一般 clarification benchmark 常处理实体、版本、事实错误、目标或工具参数不清。ElicitAlign-Bench 只保留一种更窄的欠指定：初始请求对于生成一份通用报告已经足够，但对于选择最适合特定用户的证据、比较标准或行动建议仍然缺少关键信息。缺失信息必须满足三个条件：

1. 不同真实用户可以有不同答案；
2. 该答案会改变至少一个预先冻结的推荐、筛选标准、风险边界或交付结构；
3. 如果不知道该答案，agent 仍可生成貌似合理的通用报告，因此“直接执行”具有真实诱惑。

这一定义紧贴 G-STEER 的 framing-factor setting，因此不能只靠定义声称新颖。新的证据必须来自无提醒自然条件、完整 persona oracle、成对用户反事实、充分信息负对照和最终交付物利用检验的联合实验。

1.3 不能把“主动关心用户”当成内部心理状态

本研究不声称模型真正“在意用户”或“理解用户”。可观察主张仅限于：系统是否在没有额外提示时表现出自主用户状态发现与利用行为。所有结论都针对行为轨迹和最终产物，不推断内部动机。

2. 核心研究问题与可证伪假设

2.1 研究问题

- **RQ1 自主发现：** 在缺少决策相关用户信息、但没有澄清提醒时，agent 是否会主动识别需要询问？
- **RQ2 有效询问：** 它询问的是会改变决策的变量，还是泛泛收集人物背景？
- **RQ3 充分停止：** 它能否在关键变量已解决后停止，同时避免在充分说明的任务上过度提问？
- **RQ4 从回答到交付：** 获取到的用户事实是否正确改变检索、比较标准和最终建议，同时保持共同任务质量？
- **RQ5 能力分解：** 完整 persona 表现、被提醒后的澄清表现和无提醒自然表现是否给出不同的系统排名？

2.2 预注册假设

- **H1 自主交互收益：** Natural-Interactive 相比 No-Ask 提高目标用户最终交付效用，且共同内容质量不低于预设 non-inferiority margin。
- **H2 主动性缺口：** Nudge-Interactive 相比 Natural-Interactive 的提升在部分系统上显著，说明系统具备被提示后执行的能力，却没有稳定自主调用它。
- **H3 oracle 缺口：** Full-Persona Oracle 仍高于 Natural-Interactive；该差距可进一步归因于漏问、问错、过早停止或获取后未利用。
- **H4 排名重排：** 至少一组系统在 Full-Persona Oracle 与 Natural-Interactive 下发生稳定排名变化；否则新 benchmark 很可能只是增加交互成本，而没有识别新能力。

- **H5 选择性：** 高质量系统在 Critical-Missing case 上提问，同时在 Sufficient 与 Irrelevant-Missing control 上保持低过问率。

3. 一个 benchmark case 到底包含什么

3.1 Task family：共同任务不变，用户决策条件改变

一个 family 由一个共同 research task shell 和至少两个用户状态组成。任务、可用证据、工具、预算上限和交付格式固定；用户 A 与用户 B 只在 2-4 个会改变决策的变量上不同。例如，共同任务是“比较三种小团队知识库方案并给出迁移建议”：

- 用户 A：预算低、没有专职 IT、需要中国大陆稳定访问、最重视两周内迁移；
- 用户 B：预算较高、有 DevOps、处理受监管数据、最重视审计与权限隔离。

这两位用户不需要有长篇人格故事。每个差异都必须对应一个可审计的“为什么会改变建议”。

3.2 五类元数据

Case metadata 记录整个可运行实例：case_id、family_id、版本、来源、语言、领域、风险等级、构建者、审核者、可公开性和冻结时间。

Task metadata 记录共同任务：研究意图、使用情境、交付物、证据依赖、时效性、搜索 fan-out、工具与预算、成功条件、共同事实核心和允许的答案空间。

User-state ledger 是不提供给主实验 agent 的真值账本。每个字段标注：值、证据来源、敏感度、是否可直接询问、是否允许从历史推断、稳定性、决策相关性和信息缺失后会改变的节点。

Underspecification metadata 记录从完整任务中拿掉了什么、为什么仍然自然、缺失属于 critical / irrelevant / none、可通过什么问题恢复、错误默认会造成什么后果。

Evaluation contracts 包括 must-change、must-hold、must-not。must-change 规定知道用户差异后哪些结论应改变；must-hold 规定共同事实和证据标准不应改变；must-not 规定不得猜测、不得越权追问或不得披露的内容。

3.3 元数据由谁标

- 来源、日期、文件类型、环境版本和证据快照哈希自动导入，人工抽查；
- 哪些用户变量会改变决策、缺失严重性、must-change/must-hold/must-not 由两名标注员独立标注并仲裁；LLM 可以预填，但不能成为真值；
- 运行后难度、模型分歧、失败类型和成本作为观测结果另存，不能反向覆盖预先标签。

3.4 Persona 如何真实自然

首选数据来自真实用户任务。参与者提供一个真实 research task shell，并说明做决定时哪些条件真正重要。研究者把信息整理为最小 user-state ledger，再由本人逐项确认。若找不到共享同一任务的第二位真实用户，可构造最小反事实用户，但必须由另一位目标人群参与者验证其自然性。纯 LLM 合成 persona 只用于工程 smoke test，不作为主实验真值。

4. 四个核心实验条件

所有条件使用相同 backbone、搜索工具、证据快照、预算和输出要求；只改变用户信息和交互政策。

条件	Agent 看到什么	能否问用户	这个条件回答什么
C0 Natural-Interactive	自然欠指定 instruction；不出现“个性化/澄清”提醒	可以	系统是否会自主意识到并采取行动
C1 Nudge-Interactive	同一 instruction，外加“若缺少会改变答案的用户信息，可先澄清”	可以	被提醒后是否具备提问与利用能力

条件	Agent 看到什么	能否问用户	这个条件回答什么
C2 No-Ask	同一欠指定 instruction	不可以	没有澄清时的通用回答下限
C3 Full-Persona Oracle	完整且已验证的相关 user-state ledger	不需要	已知全部相关信息时的可达到上限

主比较是 C0-C2；C1-C0 是“自主触发缺口”；C3-C1 是“澄清执行与信息恢复缺口”。C3 不是参考文本答案：oracle 条件的 agent 仍可能研究或推理失败，所以四个条件都要接受相同最终评分。

4.1 为什么主条件不能提醒

若 system prompt 明确要求“先考虑个性化并发起澄清”，实验测到的是提示遵从，不是自主发现。Nudge 仍然重要，但只能作为诊断和可修复性上限。

4.2 为什么不能只选大家都会问的任务

按 pilot 中“多数模型会问”来筛题会产生行为选择偏差：擅长主动询问的模型定义了数据分布，差模型也会因明显提示获得高分。正确做法是先根据人类决策逻辑冻结缺失变量，再让模型暴露差异。正式集应包含 obvious、subtle、sufficient 和 irrelevant-missing 四种 case，而不是只保留明显欠指定任务。

5. 交互协议与用户模拟

5.1 用户模拟器只负责回答，不替 agent 规划

模拟器读取隐藏 ledger，但只能根据 agent 的实际问题回答。它不得主动泄露未被询问的关键变量，不得提示下一步应该问什么，也不得复制 rubric。回答可采用自然表达，但语义必须映射到

冻结字段。对间接问题，模拟器根据预定义 answerability 规则决定直接回答、部分回答、拒绝或请求重述。

5.2 人类效度层

主榜可以使用经过验证的模拟器以控制成本，但必须抽取不少于 20% 的 case 由真实用户重放。至少报告：模拟器与本人回答的一致率、agent 在两种回答源下的行为重排、真人认为问题是否自然/必要、以及模拟器是否过度配合。若人类与模拟器导致显著不同的系统排序，模拟结果只能作为开发集诊断。

5.3 停止并不是“问满固定轮数”

最大轮数只防止无限交互，不能定义成功。成功停止应满足：所有 unresolved critical nodes 已解决，或剩余不确定性不足以改变允许的推荐集合；同时没有为提高覆盖率而继续询问低价值或敏感信息。

6. 评分：不再用一个直接差值讲完整故事

6.1 轨迹层 profile

- **Need Detection**：critical-missing case 是否发起有效询问；sufficient control 是否不问。用 sensitivity、specificity 和 macro-F1 分开报告。
- **Targeted Elicitation Recall**：冻结的关键用户变量中，有多少被问题和回答成功解决。
- **Question Precision**：已问内容中，有多少对应决策相关节点，而非无关人物信息。
- **Information Gain per Turn**：每轮解决的加权关键节点数；权重在运行前按决策影响冻结。
- **Stopping Sufficiency**：停止时是否仍存在会改变建议的 unresolved node。
- **Burden**：提问轮数、用户输入 token、重复问题和总等待时间。
- **Boundary**：不必要敏感提问、越权推断、拒答后追问和未经许可使用历史的次数。

6.2 交付物层 profile

- **Absolute Adequacy:** 每个条件的交付物是否先达到最低可用标准；不能因为相对别的条件更好就算成功。
- **User-specific Contract Compliance:** 应改变的提议是否改变、共同事实是否保持、禁止内容是否避免。
- **Common Quality / Factual Reliability:** 深度、逻辑、清晰度、引用支持和事实可靠性不能因个性化而下降。
- **Target-user Utility:** 目标用户或预冻结决策 oracle 对可接受方案、硬约束违规和选择质量的评价。

6.3 三个核心效应，而不是单一总分

设同一 family、同一系统在 C0-C3 下的最终用户效用为 U0-U3：

SelfInitiatedGain	= U0 - U2	# 自主询问相对不能问带来多少收益
NudgeGap	= U1 - U0	# 提醒后多出来的能力，反映自主触发缺口
OracleGap	= U3 - U0	# 距完整用户信息上限还有多远

这些差值必须与四个 arm 的绝对分同时报告。论文不会把“差值大”自动解释为好：如果 U0 本身没有通过 adequacy 门，即使 U2 更差也不能称为成功。

为了便于不同 family 比较，可把 oracle recovery 作为次级描述量：

$$\text{OracleRecovery} = (U0 - U2) / (U3 - U2)$$

仅当 U3-U2 大于预注册阈值 ϵ 时计算；不将该比率作为主检验，不对负分母或极小分母强行归一化。主统计始终使用原始 arm 与成对效应。

6.4 “问到了但没用”必须单独识别

对每个 must-change node 记录 `unknown` → `asked` → `answered` → `represented_in_plan` → `evidenced_in_report` → `changed_decision`。只有字段被正确获取且对应交付物叶节点改变，才算 utilization success。这样可以区分：

- 没发现；
- 发现但问题不精确；
- 问到了但过早停止；
- 信息进入计划却在长程执行中丢失；
- 最终报告提到用户事实，却没有改变建议。

7. 数据规模、统计单位与主分析

7.1 两阶段构建

Novelty-kill pilot: 3 个 family × 2 位用户 × 4 case type × 4 条件 × 4-6 个系统。目的不是发表显著性，而是检查能否出现新诊断、排名重排和合理成本。

正式 benchmark: 若 pilot 通过，扩到 24 个 family，覆盖消费/旅行/职业、企业采购/技术/合规、学术研究三类使用情境。每个 family 至少含一对 critical-missing 用户实例和一个 sufficient 或 irrelevant-missing control。

7.2 为什么统计单位是 family

同一 family 内的两个用户、四个条件、多个随机种子共享任务、证据和 rubric，不能当成独立样本。主分析以 family 为 cluster：family-blocked permutation 在 family 内交换条件标签；cluster bootstrap 每次抽取整个 family。系统比较报告 family-level paired effects、置信区间和 effect distribution，不只给平均榜单。

7.3 成功门

一个系统只有同时满足以下条件，才能被称为“成功自主恢复个性化信息”：

- 1. critical-missing 条件下有足够 need detection，同时在 sufficient control 上不过问；
- 2. Natural 相比 No-Ask 提升目标用户效用；
- 3. Natural 交付物达到绝对 adequacy，并且共同质量和事实可靠性不下降；
- 4. 无隐私、权限或敏感提问违规；
- 5. 获取的信息确实触发预期 must-change，而不是只被复述。

这些门不可互相补偿，不合成为一个不透明总分。

8. 与最近邻的精确边界

工作	已经解决什么	ElicitAlign-Bench 还必须证明什么
PDR-Bench	给定 persona/context 后的报告个性化、质量和可靠性	不给 persona 时能否自主恢复相关用户状态；完整 persona 仅作参考
IDRBench	欠指定 Deep Research 的持续交互收益和成本	不是强制外挂统一 interaction module，而是测原生 agent 是否自行触发；使用成对用户契约
IntentRL	主动澄清潜在 intent 的训练方法与下游提升	benchmark 通用系统的自然主动性、充分负对照和信息到交付的逐节点利用
DiscoBench	搜索路径中的动态歧义发现、提问与事实恢复	缺失的是用户决策条件而非事实答案；终点是用户特异的长报告与建议
G-STEER	个性化 DR 中 Retrieve/Ask/Stop、target coverage、问题负担和下游 P/Q	无静态 profile、无专用 refiner 提醒的 natural condition；paired real-user ledger、sufficient controls、oracle/rank decomposition 与真人重放

最危险的审稿意见会是：“这只是 G-STEER 的 benchmark 化，加上更多对照。”只有当实验发现现有 PDR/G-STEER-style 指标无法解释的系统重排或失败类型，而且这些差异能被真人和最终交付 contracts 验证时，才有足够独立性。

9. 工程实现

9.1 最小环境

第一版只搭一个 frozen web research harness：固定网页快照或文件包、统一搜索接口、同等 token/tool 预算、可暂停的用户通道、完整事件日志和可重放 user simulator。无需同时搭三个环境。商业产品只在主协议跑通后做 smoke test，因为产品版本、内置 clarification 和不可控网页会混淆主因果比较。

9.2 Rubric compiler

现在就冻结 node registry，但不追求一次列完。compiler 根据 task metadata、user-state decision links 和三个 contracts 选择：

- 通用任务质量 nodes；
- factuality / citation nodes；
- 用户约束和偏好 nodes；
- must-change / must-hold / must-not nodes；
- clarification trajectory nodes；
- privacy / permission nodes。

只有一个新构念在至少两个 family 重复出现、对决策重要且无法通过现有 node 参数化时，才新增 node。禁止看完模型输出后为了抓某个模型的错误临时加 rubric。

10. 最小实验和方向否决标准

10.1 三个 pilot family

1. 小团队知识库采购：预算、IT 能力、合规与迁移时限；
2. 国际家庭旅行规划：签证/护照、儿童年龄、行动限制、风险容忍度；
3. 研究工具选型：数据敏感性、团队技能、复现要求、算力预算。

每个 family 先由 LLM 生成 shell 和两位 persona，再由研究者逐条检查“真实、自然、会改变决策、可问、无答案泄漏”。LLM 合成只验证 harness 与评分逻辑，不支持论文效度结论。

10.2 继续条件

- 至少两个 family 出现 Natural、Nudge、No-Ask、Oracle 的有意义分离；
- 至少一个系统发生 Full-Persona 与 Natural 排名变化，或出现稳定的“问得好但用不好”诊断；
- sufficient control 的过问率不是全系统接近 100%；
- 两名人工评分者对关键 must-change/must-hold 的一致性达到预设标准；
- 运行成本允许在八周内完成 24 family。

10.3 停止或换题条件

- 所有系统只要收到 Nudge 都近乎达到 Oracle，Natural 差异只是一个 prompt trick；
- G-STEER / IDRBench 指标已经完全预测本 benchmark 排名，没有新增解释；
- 合理用户之间无法就“哪些缺失信息会改变决策”达成可接受一致；
- user simulator 与真人导致明显相反的系统结论；
- final deliverable 的差异主要来自长度、搜索预算或总体模型能力，而非 elicitation。

11. 预期贡献与主张边界

若实验通过，论文可以主张三项贡献：

- 1. 一个自然欠指定的个性化 Deep Research benchmark，数据单元是 paired user task family，而不是显式 persona-query 对；
- 2. 一个四条件能力分解，把自主触发、被提醒后的执行、禁止询问下限和完整 persona 上限分开；
- 3. 一个从 clarification 到 final delivery 的可追溯评价协议，联合测 need detection、targeted elicitation、stopping、utilization、共同质量和边界。

论文不能主张：首次研究 clarification、首次研究 interactive Deep Research、首次研究 personalization、模型真正关心或理解用户、一个总分代表全部能力，或 synthetic user 足以替代真人。

12. 八周执行计划

周次	交付
第 1 周	冻结三 family、ledger、case type、contracts 与四条件 harness
第 2 周	运行 4-6 个系统的 novelty-kill pilot；人工复核轨迹和交付物
第 3 周	根据停止门决定继续/收窄/换题；冻结 schema、rubric nodes 和 simulator 协议
第 4-5 周	扩建 24 family；双人标注与仲裁；完成开发集
第 6 周	主实验、多随机种子、family-clustered 统计；真人重放子集
第 7 周	judge 校准、消融、排名重排和最近邻正面对照

周次	交付
第 8 周	论文、数据卡、代码、复现实验和投稿前审稿模拟

参考文献

[1] [One Interaction Is Worth a Thousand Guesses: Benchmarking the Interactive Capabilities of Deep Research Agents](#). 2026.
[2] [IntentRL: Training Proactive User-intent Agents for Open-ended Deep Research via Reinforcement Learning](#). 2026.
[3] [When Search Agents Should Ask: DiscoBench for Clarification-Aware Deep Search](#). 2026.
[4] [Personalized Deep Research Query Refinement with Graph-Scaffolded Evidence Grounding](#). 2026.
[5] [Towards Personalized Deep Research: Benchmarks and Evaluations](#). ICLR 2026.
[6] [Ask Early, Ask Late, Ask Right: When Does Clarification Timing Matter for Long-Horizon Agents?](#). 2026.
[7] [Ask-before-Plan: Proactive Language Agents for Real-World Planning](#). EMNLP Findings 2024.
[8] [Tell Me More! Towards Implicit User Intention Understanding of Language Model Driven Agents](#). ACL 2024.
[9] [Learning to Ask: When LLM Agents Meet Unclear Instruction](#). 2024.
[10] [CLAMBER: A Benchmark of Identifying and Clarifying Ambiguous Information Needs in Large Language Models](#). ACL 2024.

AI 辅助说明

本 proposal 使用 AI 工具辅助检索、结构化、写作和文件生成。所有研究主张、文献边界、实验条件和继续/停止标准仍需作者人工核验；任何 LLM 生成的 persona、rubric 或评分均不得直接作为正式 benchmark 真值。