

PLAIN-LANGUAGE RESEARCH PROPOSAL

DeepAlign-Bench | 完整人话版

方法、假设与实验不变，把每一步说清楚

适合组内共识 · 导师讨论 · 正式写作前校验

文档版本	v0.13 · 完整人话版
日期	2026 年 8 月 2 日
研究主线	为什么测 · 测什么 · 怎么测 · 如何判分 · 能声称什么

核心命题

同一任务和证据下，只改变用户；匹配用户的结果必须优于错配结果，而且事实 and 共同质量不能变差。

内容导航

1. 为什么现有评测不够
2. Case、Task 与 Persona 怎么构建
3. 实验如何运行
4. 最终交付物与过程怎么分工
5. Rubric、Metrics 与 Judge
6. 失败分类
7. 两个月执行计划
8. 顶会评审问题与论文主张边界
9. 参考文献

阅读方式：先看主图和研究概要；需要执行细节时看第 4-11 节；需要审稿防守时看第 12-13 节。

研究概要

一句话说明

我们要测的不是 Deep Research agent 能不能写出一份“看起来不错”的报告，而是：同一个研究任务交给不同用户时，它能不能根据用户真正相关的信息，交付不同但都正确的结果。

例如，两个人都问“我应该选哪一个硕士项目”。学校信息完全相同，但一个人预算紧、希望尽快就业，另一个人准备读博、重视科研训练。合格的 agent 不只是把两人的背景各写一遍，而应该改变比较标准、证据重点、风险提醒和最后建议。同时，学校事实、引用质量和基本分析不能因为“个性化”而变差。

我们真正要回答的五个问题

1. 给 agent 不同形式的用户信息，最后的交付物是否真的更适合这个用户？
2. 这种差异是不是来自用户信息，而不是报告更长、格式更漂亮或说了更多好听的话？
3. agent 会不会忽略、误用、过度使用或泄露用户信息？
4. 在长任务、信息冲突、子 agent 交接或用户中途改主意时，个性化能力会不会丢失？
5. 我们设计的 rubric 和 judge 能不能稳定识别上述差异，而不是只学会偏爱某种写作风格？


两个月内要完成什么

主实验固定为 24 个 task family、每题两个强对比用户、4 种用户信息条件和 3 类 agent，最多 576 个 episode；其中 8 个 family 负责压力测试。另建 240-unit JudgeBench，并对至少 20% 输出做人评。这个规模用于验证方法，不声称覆盖所有 Deep Research 模式；未测试、不适用和延期组合都会明确标出。

研究流程：从用户信息到可信的个性化评测

DeepAlign-Bench：长程 Deep Research 个性化交付物评测

五平面 Atlas 元数据 × 行为测试算子 × 反事实任务族；两个月用分数因子设计完成可审计覆盖



1. 为什么现有评测不够

1.1 高质量不等于适合用户

现有 Deep Research benchmark 大多关注：答案是否正确、搜索是否充分、引用是否可靠、报告是否完整。这些都重要，但它们回答的是“报告好不好”，没有直接回答“报告对这个用户好不好”。

如果给 agent 一份 persona 后得分更高，仍然可能有三种替代解释：

- persona 让 prompt 更长，模型因此写得更多；
- judge 喜欢报告复述用户背景；
- persona 给了额外任务信息，而不是个性化信息。

因此，单纯比较 task-only、context 和 persona 三组平均分，不能证明 agent 真正在利用用户模型。

1.2 我们采用反事实对照

一个任务 family 中，任务、证据、工具和预算保持不变，只改变用户。分别得到：

用户 U_a + 同一任务/证据 → 交付物 Y_a
 用户 U_b + 同一任务/证据 → 交付物 Y_b

然后做交换评分： U_a 同时评价 Y_a 和 Y_b ， U_b 也同时评价 Y_b 和 Y_a 。只有 Y_a 更适合 U_a 、 Y_b 更适合 U_b ，同时共同事实和基本质量都过关，我们才说 agent 做到了个性化。

1.3 论文的核心贡献不应是“任务更多”

如果只是把 persona、任务和 agent 数量扩大，评审很容易把本项目看成 PDR-Bench 的扩展版。因此核心贡献必须是可以单独验证的方法：

1. 用统一元数据描述不同 Deep Research 场景；

- 2. 用反事实任务族识别真正的用户适配；
- 3. 用元数据自动选择适用 rubric，而不是一张表硬评所有任务；
- 4. 单独评估 judge 是否可靠；
- 5. 用压力测试区分获取、保持、利用、更新和恢复问题。

2. 一个测试样本到底包含什么

2.1 五组元数据

我们把一个 case 写成五组信息。这样做的目的不是增加术语，而是保证每次结果都能回答“在什么条件下、对什么任务、给了什么用户信息、测了什么系统”。

组别	用人话解释	主要字段
Research Task	用户到底要研究什么、拿结果做什么	使用情境、研究意图、领域、交付物、任务强度、风险
Research Environment	agent 在什么证据和工具条件下工作	frozen/live/private 证据、时效、搜索工具、预算、权限
User State	对当前任务真正有用的用户信息	目标、知识、约束、偏好、风险、受众、权限、动态状态
Signal Channel	用户信息以什么方式交给 agent	persona、对话历史、澄清、行为记录、工作区、反馈
Agent System	被测系统到底具备什么能力	模型版本、搜索、记忆、规划、多 agent、工具访问

这五组元数据组成 **Deep Research Evaluation Atlas**。Atlas 是“可测试空间的地图”，不是声称我们已经测完地图里的每一个格子。

2.2 四种行为测试

- **Acquire**：缺少关键信息时，agent 会不会提出有价值的澄清问题？

- **Preserve**：任务变长、信息变多或发生交接后，agent 能不能保留重要用户约束？
- **Use**：agent 知道用户信息后，是否真的把它落实到研究、判断和交付物？
- **Update/Recover**：用户纠正信息或改变目标后，agent 能不能更新并修复已经偏离的结果？

一个 case 等于：Atlas 中的一组坐标，加上一种行为测试，再加上事先写好的预期评价契约。

2.3 Coverage manifest

我们不会用“全面”这个词掩盖空白。每个组合都标记为：

- `tested`：进入主实验；
- `defined-only`：已经定义，但这版没有运行；
- `structurally-inapplicable`：这个组合本身不合理；
- `deferred`：合理，但因为两个月预算延后。

论文必须公开每个格子的样本量、模型数和运行条件。没有测试的格子不能用于支持结论。

3. 任务如何分类

3.1 不只分“博士题”和“日常题”

“PhD-level”和“daily”混合了用户身份、领域和任务难度。日常旅行规划可能需要大量搜索和复杂约束；博士也可能只要求核验一个事实。因此我们采用三个相互补充的维度。

3.2 使用情境

1. 个人与日常：旅行、消费、学习、职业、家庭计划；
2. 专业与企业：市场、采购、合规、技术和运营决策；
3. 学术与前沿：文献综述、prior art、研究设计和开放问题。

3.3 六类研究意图

1. 理解与综合；
2. 发现与枚举；
3. 比较与决策；
4. 评估与预测；
5. 规划、设计与排障；
6. 验证与审计。

3.4 任务强度

我们不把难度压成一个分数，而是分别标注：概念广度、逻辑层数、探索性、搜索分支数、信息时效、风险和可逆性、是否需要互动。

主数据用 18 个 family 覆盖“3 种使用情境 × 6 种研究意图”，再用 6 个 family 复测最重要或风险最高的单元，共 24 个 family。这个规模足以验证测量方法，但不足以声称每个细分类别都有稳定模型排名。

4. Persona 和用户真值怎么做

4.1 Persona 不是人物小传

Persona 只是用户状态的一种展示形式。我们真正保存的是一个与任务相关的 user-state ledger。每条信息都记录：来源、时间、可靠度、敏感程度、与任务是否相关、是否允许用于推理、是否允许写进最终交付物。

同一份 ledger 可以被转成 structured persona、自然对话历史、澄清回答或 memory 记录。不同形式必须保持语义等价，否则测到的就不是“渠道差异”，而是“信息内容不同”。

4.2 六道 persona-task 检查

1. 场景真实：这个用户自然地会提出这个任务；
2. 会影响结果：至少两条用户信息会改变内容、决策、深度、行动或披露边界；
3. 两个用户可区分：盲评者能说清楚两份正确交付物应该在哪里不同；
4. 仍有共同核心：事实、证据和基本质量要求不能随用户改变；
5. 信息最少且隐私可控：不加入完成任务不需要的个人信息；
6. 不靠刻板印象：关键偏好必须来自用户确认，不能由年龄、性别、职业等代理属性猜测。

4.3 用户信息来源

- `real_user_gold`：由真实用户确认的关键信息；
- `user_anchored`：从真实需求出发，经过隐私抽象后的主数据；
- `synthetic_control`：只用于错配、无关信息等负对照。

研究者自己推断但用户没有确认的偏好不能成为 gold。

4.4 每个 user-task 的真值包

- 所有用户都必须满足的共同要求；
- 目标用户必须满足的特异要求；
- 不得假设、不得披露或不得执行的事项；
- 可以接受的替代做法；
- 关键事实与证据；
- 严重错误对应的分数封顶；
- 应该澄清的问题以及可以不提问的替代路径；
- 两个用户的正确交付物应该在哪里不同、哪里相同。

这些内容必须在模型运行前冻结。LLM 可以帮助检查遗漏，但不能单独决定 gold。

5. 实验如何运行

5.1 核心矩阵

```
24 个 task family
× 2 个强对比用户
× 4 种核心用户信息条件
× 3 类核心 agent
= 最多 576 个核心 episode
```

四种核心条件是：task-only、structured persona、语义等价自然历史、允许主动澄清。

三类核心 agent 是：一个商业 Deep Research 产品、一个在统一搜索和工具条件下运行的通用 agent、一个可复现的开源 Deep Research agent。

代码 agent、多 agent、记忆增强系统和第二个商业产品只在适合它们的 8 个 anchor family 中测试。不能为了让表格整齐，要求每个系统运行它根本不适合的任务。

5.2 三条评测轨道

- **Frozen Core**：证据和工具固定，用于主要科学结论；
- **Live Web**：记录日期、搜索服务和网页快照，只用于生态观察；
- **Longitudinal/Interactive**：用户状态中途变化，用于保持、更新和恢复测试。

三条轨道不能混成一个总榜。商业产品版本和 live web 条件变化太快，必须单独报告。

5.3 压力测试

8 个 anchor family 会加入以下部分条件：

- 把用户 A 的 persona 错配给用户 B；
- 加入与任务无关的个人信息；
- 同时提供新旧冲突信息；
- 把关键信息埋进更长上下文；

- 在子 agent 交接时删除或保留用户模型；
- 用户中途更新目标；
- 在交付前重新提醒约束，观察能否恢复。

6. 最终交付物和过程分别怎么评

6.1 最终交付物是主榜对象

论文的主要问题是“最后交付的报告、代码、表格或网页是否适合用户”，所以最终交付物可以作为主榜对象。它能回答：结果是否适合用户、matched 是否优于 swapped、个性化是否损害事实性、是否出现泄露或过度迎合。

6.2 只看最终结果不能解释所有机制

如果报告没有体现用户约束，仅看最后结果无法知道 agent 是从未读取、执行中忘记，还是记得但没有使用。因此：

- 全部样本保存必要的工具调用、检索、权限访问和交付物；
- 过程记录主要用于隐私和权限硬检查；
- 20%-30% 子集做受控重跑，用 memory、handoff、re-anchor 等干预定位保持和恢复问题；
- 不做昂贵的逐句人工轨迹标注。

如果最后只完成 final-only 评测，论文必须把“形成、漂移、恢复”的机制性结论降级，不能用最终输出反推内部原因。

7. Rubric 如何适配不同任务

7.1 不是所有任务共用一张表

每个 case 的 rubric 由六类模块组成：

```

共同质量
+ 个性化
+ 研究意图
+ 交付物类型
+ 行为测试
+ 风险模块
= 当前 case 的 rubric

```

所有 rubric 叶节点使用同一数据格式，但只有适用的模块才会被激活。例如代码任务需要可运行测试，决策备忘录需要比较标准和风险边界，学术综述需要覆盖与证据链。

7.2 四类评价契约

- `must-change`：不同用户必须改变的内容；
- `must-hold`：所有用户都必须保持的事实和质量；
- `must-not`：不得假设、泄露、越权或迎合的内容；
- `clarify-if-unknown`：缺少关键信息时应该提问或给条件分支。

7.3 三棵 rubric tree

1. **Common Task Quality**：任务完成、事实、证据、推理、行动性、文件完整性；
2. **User-Conditional Fit**：目标、内容、深度、约束、工作流、受众、动态状态；
3. **Misuse & Boundary**：刻板化、无关个性化、过期信息、隐私、越权和过度迎合。

7.4 Rubric 进入主实验前必须过四关

1. 每个关键元数据要么对应可判断的 rubric，要么明确只用于切片报告；
2. 人写的 matched 参考结果应明显优于 swapped 或错误版本；
3. 加入无关 persona、改变篇幅或文风不能提高不相关分数；
4. judge 在不同任务、交付物、用户信息渠道和风险等级上都要单独校准。

无法稳定判断、不能区分 matched/swapped 的 rubric 必须删除或降级，不能靠调权重保留。

8. Metrics 怎么读

8.1 共同质量与事实性

- **TQ**：任务完成和基本可用性；
- **FR**：事实、证据、引用支持和来源质量。

如果共同质量或事实性不过门槛，不能靠个性化分补回来。

8.2 个性化表现

- **PF**：用户特异要求完成了多少；
- **MP**：误用、泄露、刻板化和过度迎合造成的惩罚；
- **PF - MP**：净个性化适配；
- **CFA**：匹配用户的报告相对错配报告有多少优势。

$$CFA(a, b) = 1/2 \times [U_a \text{ 对 } Y_a \text{ 相对 } Y_b \text{ 的偏好} \\ + U_b \text{ 对 } Y_b \text{ 相对 } Y_a \text{ 的偏好}]$$

CFA 大于 0 才说明“对的人更喜欢对的版本”，而不是所有 persona 条件下报告都变长了。

8.3 长程能力

- **Retention**：随着任务变长，用户适配保留了多少；
- **Recovery**：重新提醒或纠正后，表现恢复了多少；
- **Side effect**：修复个性化问题时是否损害事实、任务质量或隐私。

8.4 榜单不能只给一个总分

主榜先检查 TQ、FR 和关键隐私门槛，再报告 PF-MP、CFA、Retention、Recovery、隐私违规率、成本和时间。不同 evidence track、工具预算和 agent 类型不应混排。

9. Judge 怎么做

9.1 四层评分

1. 确定性 verifier：文件、格式、预算、权限、代码测试；
2. 证据 verifier：claim 是否有支持、引用是否覆盖、来源是否可靠；
3. 强通用 judge：按照冻结的 rubric 逐项判断并定位证据；
4. 人类：目标用户判断是否有用，领域专家判断是否专业正确。

9.2 JudgeBench

用 240 个独立判分单元测试 judge，包括：正确答案、边界答案、位置交换、长度诱饵、漂亮格式诱饵、persona 关键词堆叠、隐私泄露和应当弃权的样本。

主 judge 至少要达到预注册的一致性、位置稳定性、群体差距和校准门槛。不达标的 rubric 改成人评或不进入主榜。

9.3 为什么 SFT scorer 不是当前主线

“人工 0/1 + GPT 理由”可以训练便宜 scorer，但 GPT 理由不是新的 ground truth，它可能只是在已知标签后合理化。两个月主线采用：

确定性/证据 verifier → 强通用 judge → 20% 分层人评和分歧仲裁

只有第 4 周前已经有 240 个高质量样本且主实验不受影响时，才做 SFT scorer 附录。它必须按 task family 和 agent 隔离测试；如果不能跨 family 泛化，只能做高置信样本分流。

10. 我们要报告哪些失败

1. 缺信息时既不获取也不澄清；

- 2. 没有依据就猜用户属性；
- 3. 检索错了、漏了或拿到无关用户信息；
- 4. 明明知道预算、权限或格式要求却忽略；
- 5. 新旧信息冲突时仍使用过期内容；
- 6. 会复述用户信息，但没有落实到结果；
- 7. 在不该变化的地方强行个性化；
- 8. 越权访问或披露敏感信息；
- 9. 长任务或 agent 交接后丢失约束；
- 10.收到纠正后仍不能恢复。

这些是 case 的“预期测试目标”，不是运行结果。真实失败必须由输出或轨迹证据另行标注，并保留 other/emergent 类，避免只发现作者预设的错误。

11. 两个月执行计划

周	必须完成	如果失败怎么办
1	冻结 Atlas、schema、coverage manifest 和 24 个 family 配额	缩小 ontology，不增加新分支
2	24 个 family 草案、48 个 user state、persona 兼容性检查	删除没有稳定用户差异的任务
3	真值包、四类契约、rubric modules 和小样本人评	不能区分 matched/swapped 的 rubric 不进主榜
4	240-unit JudgeBench、judge 基线、6 个 family dry run	judge 不过门就缩成更多人评
5	三类核心 agent 跑完主矩阵	冻结版本，停止新增 agent
6	anchor 压测、20% 人评、错误 open coding	只保留证据充分的机制结论

周	必须完成	如果失败怎么办
7	统计、bootstrap、覆盖审计和论文主要表格	删除不受数据支持的支线
8	复现、结果冻结、全文整合和匿名发布材料	不新增 taxonomy、agent 或任务类型

12. 顶会评审最可能问什么

12.1 这是不是 PDR-Bench 扩大版

回答不能是“我们任务更多”。必须证明 Atlas、反事实识别、rubric compiler、JudgeBench 和长程压力测试各自提供了新的、可验证的方法贡献。

12.2 Persona 是不是作者想象

主数据必须来自真实用户确认或 user-anchored 需求。人口属性不能直接生成偏好。matched 交付物需要目标用户盲评，persona-task pairing 必须通过六道检查。

12.3 元数据很多，但真正测得很少

明确区分 ontology scope 和 empirical coverage；公开 coverage manifest、选择规则和缺口。没有测试的组合不做结论。

12.4 不同任务的 rubric 能不能比较

统一的是 rubric schema、评价契约和校准程序，不假设所有模块天然等距。论文主要报告任务内反事实效应、模块完成率和分层结果；没有共同 anchor 就不制造统一总榜。

12.5 Final-only 能不能证明形成、保持和恢复

不能。最终交付物支持“结果是否适合用户”的主张；机制性主张需要受控重跑或轨迹证据。若诊断实验没有完成，就缩小论文主张。

12.6 Judge 会不会循环定义答案

Rubric 在输出前冻结；客观项优先用 verifier；judge 只做需要语义判断的叶节点；独立 JudgeBench 和人评决定哪些指标可以进入主榜。

13. 论文最后可以声称什么

如果主要门槛通过，论文可以声称：

- 提供了一套机器可读的个性化 Deep Research 评测空间；
- 反事实任务族能区分真正用户适配和表面 persona 复述；
- 不同用户信息渠道和 agent 架构会产生可诊断差异；
- 模块化 rubric 与独立 judge 校准可以支持可复现评测；
- 若完成诊断子集，可以报告保持、更新和恢复的受控证据。

论文不能声称：已经穷尽所有 Deep Research 模式；每个细分任务都有稳定排名；一个总分可以跨 frozen/live、商业/受控系统和所有交付物直接比较；最终输出能够完整解释 agent 内部何时偏离。

参考文献

- [1] OpenCompass Team. *OpenCompass: A Universal Evaluation Platform for Large Language Models*. arXiv:2605.19276, 2026.
- [2] [ModelScope. EvalScope Introduction.](https://evalscope.readthedocs.io/en/refact_readme/get_started/introduction.html)
https://evalscope.readthedocs.io/en/refact_readme/get_started/introduction.html
- [3] Zhang et al. *Agent-SafetyBench: Evaluating the Safety of LLM Agents*. arXiv:2412.14470.
- [4] *Towards Personalized Deep Research: Benchmarks and Evaluations*. arXiv:2509.25106.

- [5] Wang et al. *LiveResearchBench: A Live Benchmark for User-Centric Deep Research in the Wild*. arXiv:2510.14240.
- [6] Sharma et al. *ResearchRubrics: A Benchmark of Prompts and Rubrics for Evaluating Deep Research Agents*. arXiv:2511.07685.
- [7] Java et al. *Characterizing Deep Research: A Benchmark and Formal Definition*. arXiv:2508.04183.
- [8] Yoran et al. *AssistantBench: Can Web Agents Solve Realistic and Time-Consuming Tasks?* arXiv:2407.15711.
- [9] Liang et al. *Holistic Evaluation of Language Models*. TMLR, 2023.
- [10] Ribeiro et al. *Beyond Accuracy: Behavioral Testing of NLP Models with CheckList*. ACL, 2020.
- [11] Reuel et al. *BetterBench: Assessing AI Benchmarks, Uncovering Issues, and Establishing Best Practices*. arXiv:2411.12990.
- [12] Sokol et al. *BenchmarkCards: Standardized Documentation for Large Language Model Benchmarks*. NeurIPS Datasets and Benchmarks, 2025.