

PLAIN-LANGUAGE RESEARCH PROPOSAL

DeepAlign-Bench | 完整人话版

方法、假设与实验不变，把每一步说清楚

适合组内共识 · 导师讨论 · 正式写作前校验

文档版本	v0.15 · 完整人话版
日期	2026 年 8 月 2 日
研究主线	为什么测 · 测什么 · 怎么测 · 如何判分 · 能声称什么

核心命题

同一任务和证据下，只改变用户；匹配用户的结果必须优于错配结果，而且事实和质量不能变差。

内容导航

1. 为什么现有评测不够
2. Case、Task 与 Persona 怎么构建
3. 实验如何运行
4. 最终交付物与过程怎么分工
5. Rubric、Metrics 与 Judge
6. 失败分类
7. 两个月执行计划
8. 顶会评审问题与论文主张边界
9. 参考文献

阅读方式：先看主图和研究概要；需要执行细节时看第 4-11 节；需要审稿防守时看第 12-13 节。

研究概要

一句话说明

我们要测的不是 Deep Research agent 能不能写出一份“看起来不错”的报告，而是：同一个研究任务交给不同用户时，它能不能根据用户真正相关的信息，交付不同但都正确的结果。

例如，两个人都问“我应该选哪一个硕士项目”。学校信息完全相同，但一个人预算紧、希望尽快就业，另一个人准备读博、重视科研训练。合格的 agent 不只是把两人的背景各写一遍，而应该改变比较标准、证据重点、风险提醒和最后建议。同时，学校事实、引用质量和基本分析不能因为“个性化”而变差。

我们真正要回答的五个问题

1. 给 agent 不同形式的用户信息，最后的交付物是否真的更适合这个用户？
2. 这种差异是不是来自用户信息，而不是报告更长、格式更漂亮或说了更多好听的话？
3. agent 会不会忽略、误用、过度使用或泄露用户信息？
4. 在长任务、信息冲突、子 agent 交接或用户中途改主意时，个性化能力会不会丢失？
5. 我们设计的 rubric 和 judge 能不能稳定识别上述差异，而不是只学会偏爱某种写作风格？


两个月内要完成什么

主实验固定为 24 个 task family、每题两个强对比用户、4 种用户信息条件和 3 类 agent，最多 576 个 episode；其中 8 个 family 负责压力测试。另建 240-unit JudgeBench，并对至少 20% 输出做人评。这个规模用于验证方法，不声称覆盖所有 Deep Research 模式；未测试、不适用和延期组合都会明确标出。

研究流程：从用户信息到可信的个性化评测

DeepAlign-Bench：长程 Deep Research 个性化交付物评测

五平面 Atlas 元数据 × 行为测试算子 × 反事实任务族；两个月用分数因子设计完成可审计覆盖



1. 为什么现有评测不够

1.1 高质量不等于适合用户

现有 Deep Research benchmark 大多关注：答案是否正确、搜索是否充分、引用是否可靠、报告是否完整。这些都重要，但它们回答的是“报告好不好”，没有直接回答“报告对这个用户好不好”。

如果给 agent 一份 persona 后得分更高，仍然可能有三种替代解释：

- persona 让 prompt 更长，模型因此写得更多；
- judge 喜欢报告复述用户背景；
- persona 给了额外任务信息，而不是个性化信息。

因此，单纯比较 task-only、context 和 persona 三组平均分，不能证明 agent 真正在利用用户模型。

1.2 我们采用反事实对照

一个任务 family 中，任务、证据、工具和预算保持不变，只改变用户。分别得到：

用户 U_a + 同一任务/证据 → 交付物 Y_a
用户 U_b + 同一任务/证据 → 交付物 Y_b

然后做交换评分： U_a 同时评价 Y_a 和 Y_b ， U_b 也同时评价 Y_b 和 Y_a 。只有 Y_a 更适合 U_a 、 Y_b 更适合 U_b ，同时共同事实和基本质量都过关，我们才说 agent 做到了个性化。

1.3 论文的核心贡献不应是“任务更多”

如果只是把 persona、任务和 agent 数量扩大，评审很容易把本项目看成 PDR-Bench 的扩展版。因此核心贡献必须是可以单独验证的方法：

1. 用统一元数据描述不同 Deep Research 场景；

- 2. 用反事实任务族识别真正的用户适配；
- 3. 用元数据自动选择适用 rubric，而不是一张表硬评所有任务；
- 4. 单独评估 judge 是否可靠；
- 5. 用压力测试区分获取、保持、利用、更新和恢复问题。

2. 一个测试样本到底包含什么

2.1 五组元数据

我们把一个 case 写成五组信息。这样做的目的不是增加术语，而是保证每次结果都能回答“在什么条件下、对什么任务、给了什么用户信息、测了什么系统”。

组别	用人话解释	主要字段
Research Task	用户到底要研究什么、拿结果做什么	使用情境、研究意图、领域、交付物、任务强度、风险
Research Environment	agent 在什么证据和工具条件下工作	frozen/live/private 证据、时效、搜索工具、预算、权限
User State	对当前任务真正有用的用户信息	目标、知识、约束、偏好、风险、受众、权限、动态状态
Signal Channel	用户信息以什么方式交给 agent	persona、对话历史、澄清、行为记录、工作区、反馈
Agent System	被测系统到底具备什么能力	模型版本、搜索、记忆、规划、多 agent、工具访问

这五组元数据组成 **Deep Research Evaluation Atlas**。Atlas 是“可测试空间的地图”，不是声称我们已经测完地图里的每一个格子。

2.2 四种行为测试

- **Acquire**：缺少关键信息时，agent 会不会提出有价值的澄清问题？

- **Preserve**：任务变长、信息变多或发生交接后，agent 能不能保留重要用户约束？
- **Use**：agent 知道用户信息后，是否真的把它落实到研究、判断和交付物？
- **Update/Recover**：用户纠正信息或改变目标后，agent 能不能更新并修复已经偏离的结果？

一个 case 等于：Atlas 中的一组坐标，加上一种行为测试，再加上事先写好的预期评价契约。

2.3 Coverage manifest

我们不会用“全面”这个词掩盖空白。每个组合都标记为：

- `tested`：进入主实验；
- `defined-only`：已经定义，但这版没有运行；
- `structurally-inapplicable`：这个组合本身不合理；
- `deferred`：合理，但因为两个月预算延后。

论文必须公开每个格子的样本量、模型数和运行条件。没有测试的格子不能用于支持结论。

3. 任务如何分类

3.1 不只分“博士题”和“日常题”

“PhD-level”和“daily”混合了用户身份、领域和任务难度。日常旅行规划可能需要大量搜索和复杂约束；博士也可能只要求核验一个事实。因此我们采用三个相互补充的维度。

3.2 使用情境

1. 个人与日常：旅行、消费、学习、职业、家庭计划；
2. 专业与企业：市场、采购、合规、技术和运营决策；
3. 学术与前沿：文献综述、prior art、研究设计和开放问题。

3.3 六类研究意图

1. 理解与综合；
2. 发现与枚举；
3. 比较与决策；
4. 评估与预测；
5. 规划、设计与排障；
6. 验证与审计。

3.4 任务强度

我们不把难度压成一个分数，而是分别标注：概念广度、逻辑层数、探索性、搜索分支数、信息时效、风险和可逆性、是否需要互动。

主数据用 18 个 family 覆盖“3 种使用情境 × 6 种研究意图”，再用 6 个 family 复测最重要或风险最高的单元，共 24 个 family。这个规模足以验证测量方法，但不足以声称每个细分类别都有稳定模型排名。

4. Persona 和用户真值怎么做

4.1 Persona 不是人物小传

Persona 只是用户状态的一种展示形式。我们真正保存的是一个与任务相关的 user-state ledger。每条信息都记录：来源、时间、可靠度、敏感程度、与任务是否相关、是否允许用于推理、是否允许写进最终交付物。

同一份 ledger 可以被转成 structured persona、自然对话历史、澄清回答或 memory 记录。不同形式必须保持语义等价，否则测到的就不是“渠道差异”，而是“信息内容不同”。

4.2 六道 persona-task 检查

1. 场景真实：这个用户自然地会提出这个任务；
2. 会影响结果：至少两条用户信息会改变内容、决策、深度、行动或披露边界；
3. 两个用户可区分：盲评者能说清楚两份正确交付物应该在哪里不同；
4. 仍有共同核心：事实、证据和基本质量要求不能随用户改变；
5. 信息最少且隐私可控：不加入完成任务不需要的个人信息；
6. 不靠刻板印象：关键偏好必须来自用户确认，不能由年龄、性别、职业等代理属性猜测。

4.3 用户信息来源

- `real_user_gold`：由真实用户确认的关键信息；
- `user_anchored`：从真实需求出发，经过隐私抽象后的主数据；
- `synthetic_control`：只用于错配、无关信息等负对照。

研究者自己推断但用户没有确认的偏好不能成为 gold。

4.4 每个 user-task 的真值包

- 所有用户都必须满足的共同要求；
- 目标用户必须满足的特异要求；
- 不得假设、不得披露或不得执行的事项；
- 可以接受的替代做法；
- 关键事实与证据；
- 严重错误对应的分数封顶；
- 应该澄清的问题以及可以不提问的替代路径；
- 两个用户的正确交付物应该在哪里不同、哪里相同。

这些内容必须在模型运行前冻结。LLM 可以帮助检查遗漏，但不能单独决定 gold。

5. 实验如何运行

5.1 核心矩阵

```
24 个 task family
× 2 个强对比用户
× 4 种核心用户信息条件
× 3 类核心 agent
= 最多 576 个核心 episode
```

四种核心条件是：task-only、structured persona、语义等价自然历史、允许主动澄清。

三类核心 agent 是：一个商业 Deep Research 产品、一个在统一搜索和工具条件下运行的通用 agent、一个可复现的开源 Deep Research agent。

代码 agent、多 agent、记忆增强系统和第二个商业产品只在适合它们的 8 个 anchor family 中测试。不能为了让表格整齐，要求每个系统运行它根本不适合的任务。

5.2 三条评测轨道

- **Frozen Core**：证据和工具固定，用于主要科学结论；
- **Live Web**：记录日期、搜索服务和网页快照，只用于生态观察；
- **Longitudinal/Interactive**：用户状态中途变化，用于保持、更新和恢复测试。

三条轨道不能混成一个总榜。商业产品版本和 live web 条件变化太快，必须单独报告。

5.3 压力测试

这里要分清两件事：**persona 与 task 匹配**用于先做出一组有效的干净题；**压力测试**是在这组题上单独改一个输入或过程因素。Anchor family 只是从 24 个 family 中选出的 8 个合适实验宿主，不是 8 种 persona，也不等于 8 种失败。

先固定目标用户、任务、证据和预算，再做以下配对改变：

- 把用户 A 的 persona 错配给用户 B ；
- 加入与任务无关的个人信息 ；
- 同时提供新旧冲突信息 ；
- 把关键信息埋进更长上下文 ；
- 在子 agent 交接时删除或保留用户模型 ；
- 用户中途更新目标 ；
- 在交付前重新提醒约束，观察能否恢复。

前三个共同对照（clean、persona swap、无关信息）在所有 anchor 上运行；冲突、稀释、handoff 和动态更新只放到确实适合的 family。Re-anchor 不是 attack，而是恢复干预；预先确定哪些样本重跑，不能看见失败后再挑样本。这样才能把“这个任务本来难”与“用户信息被错配、稀释、丢失或没有更新”分开。

每个扰动都要记录：什么保持不变、改了什么、何时插入、agent 当时能看见什么、配对 clean run 是哪一个、哪些结果应该变化/保持，以及恢复策略。对应指标分别是 ΔPF 、无关信息 invariance、冲突解析率、PF retention/AUC、handoff loss、update correctness 和 recovery gain；同时检查事实、共同质量、长度和隐私是否受损。

6. 最终交付物和过程分别怎么评

6.1 最终交付物是主榜对象

论文的主要问题是“最后交付的报告、代码、表格或网页是否适合用户”，所以最终交付物可以作为主榜对象。它能回答：结果是否适合用户、matched 是否优于 swapped、个性化是否损害事实性、是否出现泄露或过度迎合。

6.2 只看最终结果不能解释所有机制

如果报告没有体现用户约束，仅看最后结果无法知道 agent 是从未读取、执行中忘记，还是记得但没有使用。因此：

- 全部样本保存必要的工具调用、检索、权限访问和交付物；
- 过程记录主要用于隐私和权限硬检查；
- 20%-30% 子集做受控重跑，用 memory、handoff、re-anchor 等干预定位保持和恢复问题；
- 不做昂贵的逐句人工轨迹标注。

如果最后只完成 final-only 评测，论文必须把“形成、漂移、恢复”的机制性结论降级，不能用最终输出反推内部原因。

7. Rubric 如何适配不同任务

7.1 不是所有任务共用一张表

每个 case 的 rubric 由六类模块组成：

```
共同质量
+ 个性化
+ 研究意图
+ 交付物类型
+ 行为测试
+ 风险模块
= 当前 case 的 rubric
```

所有 rubric 叶节点使用同一数据格式，但只有适用的模块才会被激活。例如代码任务需要可运行测试，决策备忘录需要比较标准和风险边界，学术综述需要覆盖与证据链。

7.2 四类评价契约

- `must-change`：不同用户必须改变的内容；
- `must-hold`：所有用户都必须保持的事实和质量；

- `must-not` : 不得假设、泄露、越权或迎合的内容 ;
- `clarify-if-unknown` : 缺少关键信息时应该提问或给条件分支。

7.3 三棵 rubric tree

1. **Common Task Quality** : 任务完成、事实、证据、推理、行动性、文件完整性 ;
2. **User-Conditional Fit** : 目标、内容、深度、约束、工作流、受众、动态状态 ;
3. **Misuse & Boundary** : 刻板化、无关个性化、过期信息、隐私、越权和过度迎合。

7.4 Rubric 进入主实验前必须过四关

1. 每个关键元数据要么对应可判断的 rubric , 要么明确只用于切片报告 ;
2. 人写的 matched 参考结果应明显优于 swapped 或错误版本 ;
3. 加入无关 persona、改变篇幅或文风不能提高不相关分数 ;
4. judge 在不同任务、交付物、用户信息渠道和风险等级上都要单独校准。

无法稳定判断、不能区分 matched/swapped 的 rubric 必须删除或降级 , 不能靠调权重保留。

8. Metrics 怎么读

8.1 共同质量与事实性

- **TQ** : 任务完成和基本可用性 ;
- **FR** : 事实、证据、引用支持和来源质量。

如果共同质量或事实性不过门槛 , 不能靠个性化分补回来。

8.2 个性化表现

- **PF** : 用户特异要求完成了多少 ;
- **MP** : 误用、泄露、刻板化和过度迎合造成的惩罚 ;

- **PF - MP**：净个性化适配；
- **CFA**：匹配用户的报告相对错配报告有多少优势。

$$CFA(a,b) = 1/2 \times [U_a \text{ 对 } Y_a \text{ 相对 } Y_b \text{ 的偏好} \\ + U_b \text{ 对 } Y_b \text{ 相对 } Y_a \text{ 的偏好}]$$

CFA 大于 0 才说明“对的人更喜欢对的版本”，而不是所有 persona 条件下报告都变长了。

8.3 长程能力

- **Retention**：随着任务变长，用户适配保留了多少；
- **Recovery**：重新提醒或纠正后，表现恢复了多少；
- **Side effect**：修复个性化问题时是否损害事实、任务质量或隐私。

8.4 榜单不能只给一个总分

主榜先检查 TQ、FR 和关键隐私门槛，再报告 PF-MP、CFA、Retention、Recovery、隐私违规率、成本和时间。不同 evidence track、工具预算和 agent 类型不应混排。

9. Judge 怎么做

9.1 四层评分

1. 确定性 verifier：文件、格式、预算、权限、代码测试；
2. 证据 verifier：claim 是否有支持、引用是否覆盖、来源是否可靠；
3. 强通用 judge：按照冻结的 rubric 逐项判断并定位证据；
4. 人类：目标用户判断是否有用，领域专家判断是否专业正确。

9.2 JudgeBench

用 240 个独立判分单元测试 judge，包括：正确答案、边界答案、位置交换、长度诱饵、漂亮格式诱饵、persona 关键词堆叠、隐私泄露和应当弃权的样本。

主 judge 至少要达到预注册的一致性、位置稳定性、群体差距和校准门槛。不达标的 rubric 改成人评或不进入主榜。

9.3 为什么 SFT scorer 不是当前主线

“人工 0/1 + GPT 理由”可以训练便宜 scorer，但 GPT 理由不是新的 ground truth，它可能只是在已知标签后合理化。两个月主线采用：

确定性/证据 verifier → 强通用 judge → 20% 分层人评和分歧仲裁

只有第 4 周前已经有 240 个高质量样本且主实验不受影响时，才做 SFT scorer 附录。它必须按 task family 和 agent 隔离测试；如果不能跨 family 泛化，只能做高置信样本分流。

10. 我们要报告哪些失败

1. 缺信息时既不获取也不澄清；
2. 没有依据就猜用户属性；
3. 检索错了、漏了或拿到无关用户信息；
4. 明明知道预算、权限或格式要求却忽略；
5. 新旧信息冲突时仍使用过期内容；
6. 会复述用户信息，但没有落实到结果；
7. 在不该变化的地方强行个性化；
8. 越权访问或披露敏感信息；
9. 长任务或 agent 交接后丢失约束；
10. 收到纠正后仍不能恢复。

这些是 case 的“预期测试目标”，不是运行结果。真实失败必须由输出或轨迹证据另行标注，并保留 other/emergent 类，避免只发现作者预设的错误。

11. 两个月执行计划

周	必须完成	如果失败怎么办
1	冻结 Atlas、schema、coverage manifest 和 24 个 family 配额	缩小 ontology，不增加新分支
2	24 个 family 草案、48 个 user state、persona 兼容性检查	删除没有稳定用户差异的任务
3	真值包、四类契约、rubric modules 和小样本人评	不能区分 matched/swapped 的 rubric 不进主榜
4	240-unit JudgeBench、judge 基线、6 个 family dry run	judge 不过门就缩成更多人评
5	三类核心 agent 跑完主矩阵	冻结版本，停止新增 agent
6	anchor 压测、20% 人评、错误 open coding	只保留证据充分的机制结论
7	统计、bootstrap、覆盖审计和论文主要表格	删除不受数据支持的支线
8	复现、结果冻结、全文整合和匿名发布材料	不新增 taxonomy、agent 或任务类型

12. 顶会评审最可能问什么

12.1 这是不是 PDR-Bench 扩大版

回答不能是“我们任务更多”。必须证明 Atlas、反事实识别、rubric compiler、JudgeBench 和长程压力测试各自提供了新的、可验证的方法贡献。

12.2 Persona 是不是作者想象

主数据必须来自真实用户确认或 user-anchored 需求。人口属性不能直接生成偏好。matched 交付物需要目标用户盲评，persona-task pairing 必须通过六道检查。

12.3 元数据很多，但真正测得很少

明确区分 ontology scope 和 empirical coverage；公开 coverage manifest、选择规则和缺口。没有测试的组合不做结论。

12.4 不同任务的 rubric 能不能比较

统一的是 rubric schema、评价契约和校准程序，不假设所有模块天然等距。论文主要报告任务内反事实效应、模块完成率和分层结果；没有共同 anchor 就不制造统一总榜。

12.5 Final-only 能不能证明形成、保持和恢复

不能。最终交付物支持“结果是否适合用户”的主张；机制性主张需要受控重跑或轨迹证据。若诊断实验没有完成，就缩小论文主张。

12.6 Judge 会不会循环定义答案

Rubric 在输出前冻结；客观项优先用 verifier；judge 只做需要语义判断的叶节点；独立 JudgeBench 和人评决定哪些指标可以进入主榜。

13. 论文最后可以声称什么

如果主要门槛通过，论文可以声称：

- 提供了一套机器可读的个性化 Deep Research 评测空间；
- 反事实任务族能区分真正用户适配和表面 persona 复述；

- 不同用户信息渠道和 agent 架构会产生可诊断差异；
- 模块化 rubric 与独立 judge 校准可以支持可复现评测；
- 若完成诊断子集，可以报告保持、更新和恢复的受控证据。

论文不能声称：已经穷尽所有 Deep Research 模式；每个细分任务都有稳定排名；一个总分可以跨 frozen/live、商业/受控系统和所有交付物直接比较；最终输出能够完整解释 agent 内部何时偏离。

参考文献

- [1] OpenCompass Team. *OpenCompass: A Universal Evaluation Platform for Large Language Models*. arXiv:2605.19276, 2026.
- [2] [ModelScope. EvalScope Introduction.](https://evalscope.readthedocs.io/en/refact_readme/get_started/introduction.html)
https://evalscope.readthedocs.io/en/refact_readme/get_started/introduction.html
- [3] Zhang et al. *Agent-SafetyBench: Evaluating the Safety of LLM Agents*. arXiv:2412.14470.
- [4] *Towards Personalized Deep Research: Benchmarks and Evaluations*. arXiv:2509.25106.
- [5] Wang et al. *LiveResearchBench: A Live Benchmark for User-Centric Deep Research in the Wild*. arXiv:2510.14240.
- [6] Sharma et al. *ResearchRubrics: A Benchmark of Prompts and Rubrics for Evaluating Deep Research Agents*. arXiv:2511.07685.
- [7] Java et al. *Characterizing Deep Research: A Benchmark and Formal Definition*. arXiv:2508.04183.
- [8] Yoran et al. *AssistantBench: Can Web Agents Solve Realistic and Time-Consuming Tasks?* arXiv:2407.15711.
- [9] Liang et al. *Holistic Evaluation of Language Models*. TMLR, 2023.
- [10] Ribeiro et al. *Beyond Accuracy: Behavioral Testing of NLP Models with CheckList*. ACL, 2020.
- [11] Reuel et al. *BetterBench: Assessing AI Benchmarks, Uncovering Issues, and Establishing Best Practices*. arXiv:2411.12990.
- [12] Sokol et al. *BenchmarkCards: Standardized Documentation for Large Language Model Benchmarks*. NeurIPS Datasets and Benchmarks, 2025.