

CONDENSED RESEARCH PROPOSAL

DeepAlign-Bench

长程 Deep Research 智能体个性化最终交付物评测

正式论文 Proposal 精简版 · 约 10 页

文档版本	v0.31 · 正式精简版
日期	2026 年 8 月 8 日
研究主线	Problem · Research Questions · Method · Evaluation · Validity · Timeline

核心命题

固定任务与证据，只改变用户；用 matched/swapped 检验 specificity，用 task-only uplift 检验真实受益，再用质量与边界门槛排除伪个性化。

摘要

个性化 agent 研究已经从用户历史建模扩展到任务对话、工具调用、长程记忆和 Deep Research；[11][12][13][14][15][16] PDR-Bench 已能够评价 task-persona 条件下的 absolute adaptation，但其最佳 judge 的人类 pairwise agreement 仅 0.43，校准只覆盖 15 个 query 与两个 agent。[3] DeepAlign 的方法增量不是 rubric 更懂 persona，而是转向 **counterfactual personalization effect identification**；JudgeBench 则解决新 estimand 的测量可靠性。本项目固定任务与证据，交换两个都合理的目标用户，并用预冻结契约约束有效变化。

核心方法是反事实任务族：固定任务、证据、工具与资源预算，只改变目标用户；再将两个用户的交付物进行 matched/swapped 交换评分。只有匹配交付物稳定优于错配交付物，且共同任务质量、事实性、安全与隐私不下降时，才认定为有效个性化。评测框架包括五平面元数据、反事实任务族、元数据驱动的 rubric compiler、分层指标和独立 JudgeBench。

两个月论文版计划构建 24 个 task family、48 个核心 user-task、4 种用户信息条件和 3 类核心 agent，最多运行 576 个核心 episode；其中 8 个 anchor family 用于错配、无关信息、冲突/过期信息、长上下文稀释和动态更新测试。

1. 研究背景与问题

1.1 现有评测的不足

现有文献先解决了“研究结果一般好不好”。LiveResearchBench、PaperBench 等评价任务完成、事实、引用和报告完整性，OpenCompass 与 EvalScope 提供运行基础设施。[4][5][11][2] 这些指标是个性化不能牺牲的共同质量底线，但它们通常不回答“同一份证据对哪个用户更有用”。

随后，研究开始让评价函数随用户改变。LaMP 从用户历史评测个性化生成，PersonaLens 把丰富画像和历史放进任务型对话，PersonaMem 要求模型跟踪会变化的用户画像；[11][12][14] Setoka、PersonaTrail 和 APeB 又把用户信号扩展到异构记录、浏览轨迹和行为日志。[6][7][10] 因此，“用户理解或历史利用无人评测”已经不是可辩护的起点；这些工作主要仍以响应选择、记忆问答或单域意图为终点。

个性化也已经从“说什么”进入“做什么”。ETAPP 用人工关键点评测个性化与主动工具调用，Mem2ActBench 检查长期记忆能否落实到工具参数；[13][18] TARS 测代码解释的人类效用，PAHF 用澄清、记忆和反馈适应偏好漂移，PASB 与 PS-Bench 分别暴露持久写入和良性个人记忆带来的安全风险。[8][17][9][19] 这意味着 DeepAlign-Bench 不能把“行动、更新或风险”本身当作首创；现有终点多是离散工具/GUI 行动、分类、推荐或安全失败，还没有统一到多证据的开放式 DR 交付物。

最后，PDR-Bench 和另一项 PDR 工作已经把 persona 或动态上下文接入 Deep Research。[3][15] PDR 的 P-Score 按 task/persona 生成权重与子标准，能回答“给定用户，这份报告是否适合”；DeepAlign 改问“固定 task/evidence/resources，只换用户后，两份交付物是否各自更适合对应用户”，并以 must-change / must-hold / must-not 排除方向错误、共同事实破坏和过度推断。PDR 的测量边界也需保留：15-query/2-agent 校准中最佳 PCA=0.43；两层动态 rubric 会引入 criterion variance；human panel 不等于目标用户效度；事实分依赖 claim 抽取—去重—抓取

—支持判断链；P/Q/R 算术平均还可能补偿关键事实失败。[\[3\]](#) 这些支持独立 JudgeBench 和 hard gate，但不是 estimand 创新的替代。

1.2 研究空缺

本项目不声称首先研究 personalization、history、tool use、persistent state 或 temporal intervention；它解决的是这些方向在广义 DR 最终交付物上的识别缺口：

1. 如何从 absolute adaptation evaluation 转向 counterfactual personalization effect identification，检验只改变目标用户后交付物是否发生方向正确的变化；
2. 如何为报告、代码、表格和决策备忘录使用可组合但不强行统一的 rubric；
3. 如何区分最终交付物效用与获取、保持、利用、更新等过程机制；
4. 如何验证自动 judge 没有被长度、位置、格式和 persona 关键词误导。

可辩护的核心主张是：在广义 Deep Research 的多类最终交付物上，用 matched/swapped 用户交换和预冻结 must-change/must-hold/must-not 真值识别可观察的 counterfactual personalization effect。异构用户信号、长程干预、模块化 rubric 和独立 JudgeBench 用于检验这一效应的稳健性、测量效度与外部效度，不与核心创新并列。该协议不证明模型内部“真正理解用户”；若 matched/swapped 人评不稳定，论文将收缩为 absolute adaptation 的扩展研究。

2. 研究问题与假设

2.1 研究问题

- **RQ1：反事实适配。** 同一任务和证据下，匹配用户的交付物是否稳定优于错配用户的交付物？
- **RQ2：信息渠道。** 结构化 persona、语义等价自然历史、主动澄清和 task-only 条件如何影响个性化效果与误用风险？
- **RQ3：长程保持与更新。** 上下文稀释、信息冲突、agent 交接和用户状态更新如何影响用户适配？
- **RQ4：系统差异。** 商业 Deep Research、统一工具 harness 下的通用 agent 和开源 Deep Research agent 是否表现出稳定的失败模式差异？

2.2 可证伪假设

- **H1：** matched 交付物的用户适配显著高于 swapped 交付物，且该差异在共同质量门槛和目标用户盲评下成立。
- **H2：** 同一潜在 user-state 换成结构化 persona、语义等价自然历史或去显眼关键词改写时，核心 must-change 决策保持；渠道间利用率仍可能不同。
- **H3：** 长上下文干扰使用户特异适配比共同任务质量下降更快；动态状态变化后旧状态残留率随压力增加。
- **H4：** 不同 agent 类型在忽略约束、信息冲突、过度个性化、保持和更新失败上存在可重复差异。

如果用户间的合格结果差异无法获得稳定人类一致性，matched 不优于 swapped，或 judge 无法通过预设门槛，将缩小研究构念和论文主张，而不是通过调整权重保留结论。

DeepAlign-Bench 研究设计

DeepAlign-Bench：什么才算“有效个性化”？

从 absolute fit 转向可识别的 cross-user specificity × real-user benefit



核心问题

固定 task、evidence、tools 与 budget，只改变目标用户：交付物是否既能“认对人”，又比 task-only 真正更有用，同时不牺牲共同质量与边界？

01 · GAP

现有 absolute fit 还缺什么

给定用户 U，报告 Y 好不好？

$PF_U(Y) = \text{高}$

可能只是通用高质量，不等于用户特异

1

通用答案也能高分

没有证明“换用户就必须换结果”

2

平均 CFA 可能正负抵消

一位用户受益，另一位可能被伤害

3

比 swapped 好 ≠ 真正有帮助


swapped 很差，也会制造虚假的优势

需要“特异性”和“受益”两个 estimand

02 · IDENTIFICATION

Controlled crossover：同一题，只交换用户

固定 T / E / tools / budget / output format



Specificity $\Delta a = PFa(Ya) - PFa(Yb)$ · $\Delta b = PFb(Yb) - PFb(Ya)$

CFA mean 展示平均效应；CFA min 防止跨用户方向补偿

Benefit $Ga = PFa(Ya) - PFa(Y0)$ · $Gb = PFb(Yb) - PFb(Y0)$

Gain mean/min 回答 matched 是否真的优于 task-only

03 · CLAIM GATES

四个门同时通过，才算有效

1

双向 specificity

$\Delta a > 0$ 且 $\Delta b > 0$ ；不是平均后看起来为正

2

双向 real benefit

$Ga \geq 0$ 且 $Gb \geq 0$ ；matched 不劣于 task-only

3

共同质量 no-harm

TQ / FR / must-hold 均过门；个性化不能换分

4

边界 no-violation

must-not / 隐私 / 权限 / 安全无 critical failure

Target-user blind match effect + family-level CI

论文贡献：一套可证伪的 personalization identification protocol，而不是另一个“更细”的总分

24 families · 48 user-task

4 signal conditions · 3 core agent tracks

8 anchors · S0-S3 stress

acquire · preserve · use · update

240-unit JudgeBench

target-user + expert gold · bias tests

主张边界

识别的是最终交付物的反事实特异性；不等于证明模型内部“真理解用户”

v0.30 · confirmatory unit = task family · family-blocked permutation / cluster bootstrap · no single compensatory leaderboard score

图1 元数据定义 case，反事实任务族提供识别，rubric compiler 选择适用评价契约，分层 judge 与人评完成评分和校准。

3. 基准设计

3.1 评测对象与范围

一个 Deep Research episode 必须需要多步信息获取、验证、综合或实验，并交付供用户决策、行动、理解或后续生产使用的产物。纯事实问答、单次搜索和只需改变语气的任务不进入主集。交付物可包括研究报告、决策备忘录、行动计划、代码与技术说明、表格、幻灯片、网页或多文件项目。

3.2 Deep Research Evaluation Atlas

每个 case 用五个元数据平面定位：

1. **Research Task**: 使用情境、研究意图、领域、交付物、需求强度和风险；
2. **Research Environment**: frozen/live/private 证据、时效、工具、预算和权限；
3. **Task-conditioned User State**: 目标、知识、约束、偏好、风险、受众和动态状态；
4. **User-signal Channel**: brief、persona、clarification、history、behavior、workspace 和 feedback；
5. **Agent System**: 模型/产品版本、搜索、记忆、规划、多 agent 和工具权限。

Atlas 驱动抽样、实验条件生成、rubric 选择、结果切片和覆盖审计。每个组合标记为 tested、defined-only、structurally-inapplicable 或 deferred；未测试的组合不用于支持结论。

3.3 任务抽样与失败分类

任务按“使用情境 × 研究意图 × 需求剖面”组织。多篇论文不直接求 taxonomy 并集，而先进入 source-to-design ledger：每个来源分别标为 task seed、用户 construct、perturbation、rubric/judge 或 infrastructure，并记录采用、修改和拒绝项。每个 family 依次完成：一个端到端 vertical slice → 真实需求 seed → 冻结 task/evidence/deliverable core → 标注 stratum/intent/demand → 配对 user states → 冻结差异契约 → 编译 module/leaves → 目标用户/专家 pilot。24 个 family 中 18 个覆盖 3×6 主单元，6 个复测关键单元；若只能产生文风差异或 matched/swapped 不稳定则删除。

参考 Agent-SafetyBench，本项目分开“结果风险”和“预期失败模式”：前者回答最终错在何处，后者说明 case 设计用于暴露什么问题。预期标签不进入主 judge prompt；运行后的实际错误独立标注，并保留 other/emergent 类。

3.4 反事实任务族与用户真值

每个 family 固定任务、证据和资源，构造两个都自然且对结果有实质影响的用户。Persona 不先写 biography，而按“真实 source record → task-relevant axes → 共享 invariant core → 只改 2-4 个决策相关字段 → fact-to-contract map → 多 signal views → 负对照 → 人类验证”生成。每条事实记录来源、时间、可信度、相关性、敏感度和披露权限；structured persona、自然历史与澄清回答都由同一 ledger 编译。

每个 user-task 在运行前冻结真值包：共同要求、用户特异要求、禁止事项、可接受替代、关键证据、严重错误封顶、预期澄清点和 matched/swapped 差异预测。关键偏好必须有用户确认或可审计来源，不得由人口属性或研究者直接推断。

4. 实验设计

4.1 核心矩阵

24 task families $\times$ 2 users $\times$ 4 signal conditions $\times$ 3 agents = 最多 576 core episodes。

四种信号条件为 task-only、structured persona、语义等价自然历史和 clarification-allowed。三类核心系统为商业 Deep Research 产品、统一搜索/工具 harness 下的通用 agent、可复现开源 Deep Research agent。代码 agent、多 agent、memory system 和第二个商业产品仅在 eligibility predicate 为真的 anchor family 中测试。

4.2 评测轨道与压力测试

- **E1 Frozen Harness**：只读证据快照、统一工具/预算、paired seed，形成因果主榜；
- **E2 Live Product/Web**：使用原生商业/开源能力，记录版本、日期、地区、工具和 URL 快照，单独形成产品榜；
- **E3 Stateful Sandbox**：事件脚本在固定 checkpoint 注入澄清、冲突、handoff 和动态更新，共享前缀分叉形成压力与机制榜。

三者是运行环境，不是 agent 类型。核心模式 M1 商业产品、M2 controlled harness、M3 开源 DRA；code、multi-agent、memory-enhanced 只在适用 anchor 上做架构 probe。统一 adapter 至少实现 reset、provide_signal、run_until、inject_event、export_artifact 和 trace-level 声明。

8 个 anchor 覆盖日常决策、学习职业、金融信息、健康信息、企业采购/合规、软件生产、学术前沿和政策传播。每个先建 clean family，再按 S0 clean $\rightarrow$ S1 单轻扰动 $\rightarrow$ S2 单强扰动 $\rightarrow$ S3 两个正交扰动 运行。difficulty 用 evidence、signal、horizon、orchestration、permission、counterfactual subtlety 六维 stress vector 表示；risk、failure mode 与强度分开，不求和成伪精确难度分。

所有 anchor 运行 clean、persona swap 和 irrelevant-signal；其余 failure mode 用平衡不完全区组分配。若要跨任务比较“long context、conflict、handoff 哪种伤害更大”，主要 perturbation 至少落到 4 个适用 anchor；只落到 2 个时仅作探索性复现。Anchor 通过同任务、同前缀 control 估计受控扰动敏感度，不能仅凭异构任务相关性声称找到了内部根因。结果分四层报 base task profile、signal board、S0-S3 stress curve 和 boundary/governance board。

4.3 最终结果与过程证据

最终交付物是主榜对象，可支持用户适配、反事实优势、共同质量和误用边界的结论，但不能单独区分“未读取、遗忘、已知但未使用”。因此所有样本保存必要的工具调用、用户信息检索、权限访问和交付物；20%-30% 子集通过 memory、handoff 和 dynamic-update 的受控压力分叉做机制诊断。如果该子集未完成，论文只报告最终交付物个性化，不声称已定位内部偏移机制。

5. 评分方法

5.1 Metadata-driven Rubric Compiler

Compiler 已有机器可读 contract 和固定模板设计，不是让 LLM 对每份输出临时写 rubric。输入是冻结的 case metadata、user-state ledger、证据/权限和四类 contract；流程为：`validate` → `路由 module` → `选择 direction node` → `填入预算/证据/用户参数` → `leaf expansion` → `校验并冻结 bundle`。Module 是父级能力域，node 是“满足硬预算、匹配知识深度、遵守披露边界”这类可复用方向，leaf 才是 case-specific 原子标准。Leaf expansion 仍在运行前完成；自动 validator 和 compiler 是第 1 周实现项。

固定模板分六层：core 所有 case 必选；personalization 由 task-relevant user facts 和 must-change 激活；intent 由六类研究意图选择；deliverable 由 report / memo / workbook / code / slides / webpage / multi-file 选择；operator 用于 acquire/preserve/use/update 诊断；risk 由 stakes、permission、敏感信息和 must-not 激活。统一的是 leaf schema、适用条件和聚合规则，而不是让所有任务共用一张表。每条 leaf 显式记录 `criterion_id`、rubric owner、observable、evidence、scoring anchors、weight、hard gate、judge route 和 `direct_metric_bindings`。

预定义 library 有 36 个 module：6 Core、9 Personalization、6 Intent、7 Deliverable、4 Operator、4 Risk；每个 case 只激活适用子集。report/memo/table 先以 12-22 active leaves 做主矩阵，code/slides/web/multi-file 先作为 probe。相对 PDR-Bench 的重点不是“维度更多”，而是 module 版本预冻结、每个 personalization leaf 追溯到授权 user fact + must-change、同一 PF bundle 交叉评 matched/swapped，并用 must-hold/must-not 防止差异和过度个性化冒充分数。完整库见 `rubric_module_library.yaml`。

四类评价契约为：

- **must-change**：用户差异必须改变的内容、决策、深度、行动或披露边界；
- **must-hold**：不应随用户改变的事实、证据和共同质量；
- **must-not**：不得假设、泄露、越权或为迎合偏好而扭曲的内容；
- **clarify-if-unknown**：缺少关键信息时应提问、给条件分支或明确说明假设。

绑定规则固定为：`common/intent/deliverable leaves` → TQ (事实项同时 → FR)；`must-change leaves` → 指定用户的 PF；`must-hold leaves` → TQ + Neutral Invariance；`must-not violations` → MP / hard gate；`clarify leaves` → Clarification Correctness，无依据假设另入 MP；`operator leaves` → 与同前缀 clean control 的诊断差分。库的“全面性”由 content mapping、matched/swapped 区分力、无关 cue invariance、module 去重/消融、权重与 active/NA 分母敏感性、目标用户/专家效度和 residual-error saturation 共同验证，不由 module 数量证明。

5.2 Metrics

1. **Task Quality (TQ) / Factual Reliability (FR)**：任务完成、关键覆盖、claim 支持、引用覆盖和来源质量；
2. **Personalization Fit (PF) / Misuse Penalty (MP)**：用户特异要求完成率，以及刻板化、误用、隐私和过度迎合惩罚；

3. **Counterfactual Fit Advantage (CFA):** CFA 不直接绑定 leaf。先保留 $\Delta_a = PF_a(Y_a) - PF_a(Y_b)$ 与 $\Delta_b = PF_b(Y_b) - PF_b(Y_a)$ ，再报告 $CFA_mean = (\Delta_a + \Delta_b) / 2$ 和不可方向补偿的 $CFA_min = \min(\Delta_a, \Delta_b)$ ；只有两方向都为正才算 bilateral success；
4. **Task-only uplift:** 利用主矩阵已有 Y_0 ，报告 $G_a = PF_a(Y_a) - PF_a(Y_0)$ 、 $G_b = PF_b(Y_b) - PF_b(Y_0)$ 及 mean/min；它把“能区分用户”和“确实让用户受益”分开；
5. **Cue robustness:** 对语义等价 signal views 报告 worst-view CFA、Cue Gap、must-change/must-hold 一致率和 irrelevant-cue effect；
6. **Retention / Update:** 长程干扰下的适配保留率、动态状态采用正确率与旧状态残留率。

主榜先应用 TQ、FR 和关键隐私/安全门槛，再把 personalization 作为二维 profile 报告：跨用户 specificity (CFA) × 相对 task-only benefit (Gain)。只有 $\Delta_a, \Delta_b > 0$ 、 $G_a, G_b \geq 0$ 且共同质量/边界过门，才进入确认性成功率；不把这些指标平均成可补偿总分。

5.3 Judge 与 JudgeBench

评估采用四层级联：L0 确定性 verifier 检查文件、测试、格式、预算和权限；L1 证据 verifier 检查 claim、引用支持和来源；L2 强通用 judge 按冻结的原子 rubric 逐项给分；L3 目标用户和领域专家分别复核用户效用与专业正确性。Judge 只获得当前叶节点需要且已授权的用户信息，必须引用交付物证据并允许弃权。

JudgeBench 计划构建 240 个单元，覆盖位置交换、长度控制、漂亮格式诱饵、persona 关键词堆叠、事实更强但适配更弱、隐私泄露、边界答案和正确弃权。两个月主线为 verifier → strong judge → 20% 分层人评 + 分歧仲裁。SFT scorer 仅在第 4 周前获得足够高质量 gold 且不阻塞主实验时作为附录效率研究。

6. 数据质量、统计与可复现性

6.1 数据质量控制

Task 元数据分层处理：来源、许可、时间、哈希、工具和预算可自动导入后人工审计；intent、stakes、interaction need、counterfactual axes 与四类 contract 必须在运行前由两人独立人工标注并仲裁；实际难度、失败率和 judge agreement 只能在 pilot 后另存为 observed 字段。每个 task-persona 对必须通过六项门槛：场景真实、决策相关、用户间可区分、存在共同核心、信息最少且隐私可控、不依赖刻板印象。人类真值分工固定：领域专家评事实、证据和共同质量，目标用户确认 must-change / must-not 并盲评 matched/swapped；纯合成 persona 只用于压力测试，不能单独支撑真实用户效用。[16]

6.2 统计方案

确认性分析以 task family 为聚类单位，对双向 CFA 与 task-only uplift 做 family-blocked permutation test 和 cluster bootstrap；同一 family 的四格评分不当作独立样本。目标用户盲评报告 matched/swapped/task-only 的 pairwise

match win probability (tie=0.5) ；带 family/user/rater 随机效应的 Bradley-Terry 或 ordinal mixed model 仅作数据量足够时的敏感性分析。排名差异若小于人评与 judge 不确定性，不发布伪精确名次。

6.3 可复现与污染控制

运行记录包括模型/产品版本、搜索后端、时间戳、工具调用、交付物哈希、rubric 版本和 judge 版本。Frozen Core 保存证据快照与支持文档；Live Web 单独报告。开发集、私有测试集和 JudgeBench 对抗集分离；评分训练数据按 task family、用户、agent 和时间切分，避免同 family 泄漏。

7. 预期贡献与成功标准

7.1 预期贡献

- 1. 可扩展的 Deep Research Evaluation Atlas 和 coverage manifest ；
- 2. 从 absolute adaptation evaluation 转向 counterfactual personalization effect identification：用 matched/swapped 交叉评分、双向非补偿门和 task-only uplift，分别识别用户特异性与真实受益；
- 3. 由元数据选择适用模块的 rubric compiler 和不可补偿质量门槛；
- 4. 分离结果风险与预期失败模式的诊断 taxonomy；
- 5. 用于审计个性化评委的 JudgeBench 和可复现运行协议。

7.2 Go / No-Go 标准

- 至少 80% 的 task family 能得到稳定的人类用户差异判断；
- 参考交付物在共同质量达标时对两个用户都显示 matched 优于 swapped，且相对 task-only 的双向 uplift 不为负；
- Judge 达到预注册一致性与校准门槛，否则扩大人评并停止自动精细排名；
- 个性化效应在共同质量门槛、目标用户盲评与语义等价信号检验下仍存在；
- 两个月内完成冻结主矩阵、覆盖审计、至少 20% 人评和可复现分析；所有 real-user-gold family 与不少于 8 个分层 family 收集目标用户 matched/swapped 盲评。

8. 时间表、风险与论文边界

8.1 八周计划

周	主要产出	失败时的收缩方案
1-2	冻结 Atlas/schema；完成 24 family、48 user state 和 persona-task 检查	缩小 ontology；删除无稳定用户差异的任务
3-4	真值/契约/rubric；240-unit JudgeBench 与 6-family dry run	无区分力 module 不进主榜；judge 不过门则增加人评

周	主要产出	失败时的收缩方案
5-6	三类核心 agent 主矩阵、anchor 压测、20% 人评和错误 open coding	冻结 agent；只保留证据充分的过程结论
7-8	统计、覆盖/消融、结果冻结、复现、全文和匿名材料	删除不受支持的支线；不再增加 taxonomy 或系统

8.2 主要风险及缓解

- 用户真值不成立**：关键偏好由用户确认；双人独立标注与仲裁；删除无稳定差异的 family。
- Rubric 循环定义**：rubric 在模型输出前冻结，并通过错配、无关信息和参考交付物校准。
- 把结果效应误写成内部理解**：主张限定为反事实特异性；加入语义等价表达、去关键词改写和无关属性不变性测试。
- Judge 可靠性不足**：明确引用 PDR 的 PCA=0.43 与窄校准边界，并运行位置交换、长度匹配、wrong-user swap、关键词/隐私诱饵和弃权测试；这是测量增量，核心方法增量仍是 estimand 转换。
- 跨 agent 比较不公平**：记录工具、预算和版本；受控 harness 与端到端产品分开报告。
- 范围过大**：主矩阵只包含 24 family、4 条件和 3 类 agent；扩展系统不阻塞主论文。

8.3 论文主张边界

若只完成 Outcome Core，论文仅声称测量最终交付物的用户适配。只有当轨迹审计与受控压力分叉完成时，才报告保持与更新机制。本项目不声称首版覆盖所有 Deep Research 模式，只对 coverage manifest 中标记为 tested 的组合作结论。

8.4 开工顺序与 ICLR readiness

先从 60-80 个 seed 筛约 30 个候选，只做 3 个完整 family；优先两位真实用户，至少 2 个通过 specificity、benefit、共同质量与边界四重门后才扩到 24。工程顺序为 E1 主轨（1.5-2.5 周）→ E3 单 anchor（追加 2-4 周）→ E2 单产品观察性 probe（3-7 天+维护）。[ICLR 官方数据](#)显示近年总体录用率约 27%-32%；本稿无 pilot 约 5%-12%，合格执行约 20%-35%，强结果约 35%-50%，中心判断约三成。它是审稿风险区间，不是校准概率。

参考文献

[1] [OpenCompass](#). 2026.

[2] [EvalScope documentation](#). 2026.

[3] [Towards Personalized Deep Research: Benchmarks and Evaluations](#). 2025.

[4] [LiveResearchBench](#). 2025.

[5] [PaperBench](#). OpenAI, 2025.

[6] [Setoka](#). 2026.

[7] [PersonaTrail](#). 2026.

[8] [IARS](#). 2026.

[9] [Agents Don't Just Agree. They Remember](#). 2026.

[10] [APeB](#). 2026.

[11] [LaMP](#). ACL, 2024.

[12] [PersonaLens](#). Findings of ACL, 2025.

[13] [ETAPP](#). ACL, 2025.

[14] [PersonaMem](#). 2025.

[15] [Personalized Deep Research](#). 2026.

[16] [MyScholarQA](#). ACL, 2026.

[17] [Learning Personalized Agents from Human Feedback](#). 2026.

[18] [Mem2ActBench](#). ACL, 2026.

[19] [When Personalization Legitimizes Risks](#). ACL, 2026.