

CONDENSED RESEARCH PROPOSAL

DeepAlign-Bench

从绝对适配到反事实用户特异性

正式论文 Proposal 精简版 · 不超过 10 页

文档版本	v0.54 · 正式精简版
日期	2026 年 8 月 16 日
研究主线	Specificity · Adequacy · Benefit · No-Harm · Boundary

核心命题

单用户绝对适配分不能证明反事实用户特异性；必须用 paired users、task-only 和非补偿门共同识别。

摘要

[PDR-Bench](#) 已经回答了一个重要问题：给定 task 与 persona，一份 Deep Research 报告在目标、内容、呈现和可行动性上有多适合该用户。[\[1\]](#) 但单个 user-task pair 的绝对适配分不能识别另一件事：固定任务、证据、工具和预算，只改变目标用户后，系统是否会做出方向正确且只对该用户必要的改变。高质量通用报告可能对两位用户都高分；大量复述 persona 的报告也可能在最终选择上用错关键约束。

DeepAlign-Bench 为同一 task family 构造两位都真实合理、但有 2-4 个决策相关差异的用户 A/B。系统生成 task-only 和两份 matched artifact，两套用户标准再交叉评价。结果不压成总分，而同时报告双向 specificity、matched 绝对合格、相对 task-only 的新增收益、共同质量/事实 no-harm 与边界 no-violation。v0.54 把这一协议谨慎地实例化在 open-web research、repository-level software engineering 和 data-centric analysis 三个场景，对应 `find & synthesize` / `modify & build` / `analyze & infer`；不声称穷尽所有知识工作。

v0.54 任务资源池有 180 个候选 seed (72 DR / 54 Software / 54 Data)。五道作者阶段门预选 60 个 provisional family (24 / 18 / 18)，来源为 39 benchmark-derived、12 adapted-real-world、9 newly-authored。这 60 个是等待许可审计、环境绑定、双人反事实审查、contract freeze 和 pilot discrimination 的 task shell，不是已可运行 gold。主论文优先完成 12 个端到端 family (5 DR / 3 Software / 4 Data)。

2026-08-12 的两-family、本地 Qwen3-8B PDR-compatible 压力测试给出明确 go 信号：general-good 报告 4/4 次与 matched 相差不超过 0.5 分；over-personalized 报告只有 1/4 次接近 matched，因此不支持“普遍误判”的强 claim；两个 family 的 `A_min` 均很高，但 `CFA_min` 分别为 -1.50 与 0.00，证明绝对合格与双向特异性可以脱钩。该结果不是官方 PDR 复现；下一步必须用经授权的 GPT-5 配置和两名盲化人评复现。

DeepAlign-Bench 整体研究设计

DeepAlign-Bench: 三个长程知识工作场景

正式 Proposal v0.54 · 180 候选 → 60 provisional → 12 主论文 family → 2x2 交叉评分 → 非补偿证据门

核心贡献: Counterfactual Specificity
adequacy · benefit · no-harm · no-violation 分析

1 Case Factory: 先冻结“测什么”

180 seeds: 72 DR / 54 Software / 54 Data → 预选 24 / 18 / 18 → 主论文 5 / 3 / 4




2 Counterfactual Task Family




3 Metadata-driven Rubric Compiler




4 统一长程 Knowledge-work Episode




5 主 Benchmark: 反事实 Artifact Evaluation




6 可选外部验证: 真实目标用户随机化 Decision Trial (不是全榜必做)



7 Benchmark 能测出的“系统差异”




8 纵向 / 压力诊断 (次级)



9 统计与审计: 不制造伪精确



10 这套 Benchmark 最终能回答什么?



11 PDR 压力测试: 三层结果不能跨级解释



12 从 provisional shell 到 runnable family: 数量不冒充完成度

图例: 数据/工程 主因果链 诊断/下一步 运行/进度 资格门/风险
统计单位: task family; clarification, seed, judge report 均不冒充独立任务, contracts 与反例在评分前冻结。版本节点 · 2026-08-16
60 provisional shells ≠ 60 runnable gold families

图 1 180 候选 → 60 provisional → 12 主论文优先 family; DR/Software/Data = 40/30/30。

1. 核心缺口与主张边界

PDR-Bench 的 P-Score 是 **absolute adaptation**：针对目标用户生成 task/persona-conditioned criteria，再评价这一份报告。DeepAlign 的 estimand 是 **counterfactual user specificity**：同一任务下，A 报告是否更适合 A、B 报告是否更适合 B，而且两个方向都成立。

两者不是谁取代谁：

- absolute adaptation 回答“这份报告对用户 A 是否合适”；
- counterfactual specificity 回答“如果目标用户从 A 变为 B，交付物是否按预先定义的决策差异改变”；
- task-only gain 回答“这种改变是否比一份普通高质量报告多带来收益”；
- no-harm / no-violation 回答“个性化是否破坏共同事实、基本质量或边界”。

论文只主张最终交付物具有可观察的反事实用户特异性，不声称模型内部真正理解、在意或关心用户。若真人 decision trial 通过，才附加主张真实决策收益。

2. 研究问题与可证伪假设

- RQ1 双向特异性：matched-A 与 matched-B 是否在 A/B 两套冻结标准下同时形成对角优势？
- RQ2 绝对充分性：matched 本身是否合格，并且相对 task-only 有超过噪声的新增收益？
- RQ3 范式鲁棒性：一次性直接提供、主动澄清、执行中更新及 memory/workspace 获取是否产生一致的关键决策和可解释的系统排序？
- RQ4 测量效度：哪些 general-good、over-personalized、mention-only 和 wrong-user artifacts 会被绝对适配分漏掉，但被交叉矩阵与 hard gate 捕获？

核心假设可被以下结果否定：多数 family 无法构造自然的 paired users；真人无法稳定地区分 matched/swapped；强系统的 CFA_min 接近零；general-good 与 over-personalized 反例没有暴露绝对分之外的新错误；或所有差异都由长度、搜索预算和一般报告质量解释。

3. Task family、Case 与元数据

一个 task family 不是主题标签，而是一份受控实验蓝图：

固定任务核心 + 固定证据世界 + 固定工具/预算/交付格式 + paired users + research episodes + contracts + artifact conditions

每个 family 包含三层元数据：

- 自动 provenance：来源、日期、文件与证据哈希、环境版本、工具权限、预算、模型和 judge 版本；程序填写、人工抽查。
- 运行前人工构念：task stratum、intent、stakes、决策节点、用户差异、must-change/must-hold/must-not、clarify-if-unknown；两人独立标注并仲裁，LLM 只能预填。
- 运行后观察：实际难度、失败类型、judge 分歧、运行成本；不得覆盖运行前真值。

Persona 从真实任务出发，不从“丰满人物故事”出发。每条用户事实必须说明为什么会改变建议、matched 应采用什么、swapped 哪里不适合、什么共同事实不得改变。优先两位真实用户共享同一任务；次选一位真实用户加经相似参与者验证的最小反事实用户；纯 LLM persona 只用于 smoke test。

4. 统一 Research Episode 与用户信息来源

“一次性、主动澄清、中途提问、memory”不是同一层类别。每个 episode 同时记录：初始任务充分性、交互时机、信息来源、载体与访问方式、可用时间和更新关系、系统能力资格。

完整范式库定义八种配置：P0 task-only closed、P1 one-shot direct、P2 pre-research clarification、P3 in-research interactive、P4 checkpoint update、P5 memory retrieval、P6 workspace grounded、P7 draft-feedback revision。首版只跑 P0/P1/P2/P4：

1. **P0**：无任务相关用户信息且不可问，作为一般高质量基线。
2. **P1**：开始前一次性给完整事实，测 information use；structured persona 与等义 history 可作为载体消融。
3. **P2**：初始 query 足以做通用研究，但隐藏 1-2 个会改变建议的事实；agent 必须主动问，模拟器只按 ledger 回答。
4. **P4**：研究中在控制 checkpoint 注入覆盖旧事实的更新，测 replanning、旧状态清除与未变事实保持。

系统不支持 ask、memory retrieval 或 checkpoint 时标记 `structurally-inapplicable`，不能算零分。P1 的 persona/history 可进入 cue-equivalence；P2/P4 改变了获取或时序机制，不能机械视为等价 cue。v0.50 已生成 3 个纯合成工程 family、6 位用户和 24 个平衡 episode，并通过结构校验；它们只用于 schema/runner/rubric vertical slice，真实用户效度尚未建立。

v0.51 已完整导入 [PDR-Bench](#) 的 50 tasks、25 structured personas、25 contexts 和 250 官方 pairs，并展开为 501 个候选用户对。v0.54 不再默认跑完 50 题，而是选出 12 个 PDR-derived shell 进入 DR provisional set。原配对只说明 task relevance，不保证 counterfactual separability；因此仍需人工冻结用户契约和 evidence world。

5. 运行条件与反例校准

主矩阵至少生成 Y_0 (task-only)、 Y_a (为 A 生成)、 Y_b (为 B 生成)。每套 A/B rubric 同时评价 Y_a 、 Y_b 和 Y_0 ，不能为 swapped 临时改标准。

JudgeBench 另放四种预冻结反例：

- **general-good**：事实充分、结构清楚，但不实现用户间 must-change；
- **over-personalized**：反复使用 persona 线索，却故意把一个关键 decision node 用错；
- **mention-only**：提到了约束，但最终建议没有采用它；
- **irrelevant/persona-keyword**：加入显眼但任务无关的用户信息，测试关键词奖励和刻板化。

评估必须分开判断 `mentioned` → `reasoned/planned` → `adopted in final decision` , 不能把“出现相关词”当成“按约束执行”。

6. Scoring : 不是再算一个不透明差值

令 $PF_i(Y_j)$ 表示用户 i 的冻结标准对报告 j 的适配分 :

- $\Delta a = PF_a(Ya) - PF_a(Yb)$
- $\Delta b = PF_b(Yb) - PF_b(Ya)$
- $CFA_{min} = \min(\Delta a, \Delta b)$: 双向最差特异性 ; 一边为负即失败。
- $A_{min} = \min(PF_a(Ya), PF_b(Yb))$: 防止 `matched` 绝对很差但差值很大。
- $Ga = PF_a(Ya) - PF_a(Y0)$, $Gb = PF_b(Yb) - PF_b(Y0)$, $Gain_{min} = \min(Ga, Gb)$: 防止只因 `swapped` 特别差而显得成功。

这些仍包含差值 , 但差值只负责估计受控条件变化的效应 , 不再被误用为完整成功分。PF leaf 先统一到 $[0, 1]$, 所以 Δ 已是量尺范围归一化百分点 ; 再除以 `matched+swapped` 会在低分区放大噪声。向量夹角只诊断两个方向是否一致 , 不能保证幅度或绝对合格。

一个 family 只有同时过五道门才算成功 :

1. Δa 、 Δb 都超过预注册最小实际重要差异 ;
2. A_{min} 过绝对合格线 ;
3. $Gain_{min}$ 达到 task-only non-inferiority ; 只有超过 added-value margin 才称新增收益 ;
4. TQ、事实可靠性、must-hold 不下降 ;
5. critical must-not、隐私与权限零严重违规。

最终 leaderboard 展示 profile 和 family-level 置信区间 , 不给一个可补偿总分。统计单位是 task family : permutation 在同一 family 内交换条件标签 ; bootstrap 每次重抽整个 family ; 不同用户、seed、judge repeat 和 rubric leaf 不冒充独立样本。

7. 最小实验结果与当前证据等级

候选	absolute-high	与 <code>matched</code> ≤ 0.5	解释
general-good	4/4	4/4	强烈支持 absolute fit 不能单独证明 specificity
over-personalized	4/4	1/4	不支持“普遍近 <code>matched</code> ” ; 提示 critical error 可能被平均补偿

交叉矩阵中，F02 的 $A_{\min}=8.50$ ， $CFA_{\min}=-1.50$ ；F04 的 $A_{\min}=10.00$ ， $CFA_{\min}=0.00$ 。F02-A 还出现 wrong-user 报告 10.0、matched 8.5：judge 把比较表中“提到本地存储”误当成最终推荐采用本地部署。F04-A 的多类报告全部 10.0，显示高分饱和。

限制：只有两个合成 family、一个本地 Qwen3-8B judge；正式评分开始后因耗时减少了 judge 和重复。故本实验只支持“DeepAlign 设计值得扩展”，不能支持“官方 PDR-Bench 已被证明误判”。

v0.48 已在任何 GPT-5 结果前冻结更严格的复现：4 family、20 reports、A/B 全交叉、3 次评分重复，并精确使用 PDR 官方中文 P-Score prompt 与 5 次权重采样。预注册提交 310d9cf 推送后，OpenRouter 只读诊断确认 key 有效、有正余额且 GPT-5 可见，但无害 smoke 在进入模型前被账户/地域层 Terms of Service 403 阻断；移除 data-policy filter 与默认路由对照仍失败。当前没有 GPT-5 分数，不能把“协议已就绪”写成“官方复现已完成”。获得合规可用 key 后可从 smoke 断点续跑。

GPT-5 结果的 Introduction 证据门预先分三层。general-good 高分只证明 absolute score 不识别生成特异性，不是 PDR 打分错误；只有盲化人评确认 critical decision 失败、GPT-5 三重复仍 near-matched/rank-reversal，才是受控 evaluator 假阳性；只有该分歧跨 family、真实用户与多个系统重复，并导致系统重分类或提高真人结果预测，才是论文级 measurement-validity 证据。若 over-personalized 被稳定降分，必须撤回强缺陷叙事，不能换样本追求显著结果。

8. 预期贡献与最近邻边界

1. 固定 task/evidence/resources 的 paired-user 2x2 交叉协议，识别最终交付物的反事实用户特异性；
2. specificity $\times$ absolute adequacy $\times$ task-only benefit $\times$ no-harm $\times$ no-violation 的非补偿 profile；
3. 反例驱动的 personalization JudgeBench，专门测 general-good、over-personalized 与 mention-adoption 绑定失败；
4. 同一 ledger 下的直接 persona、自然历史和 clarification 渠道对照；
5. 可选真人 decision validation，检查 artifact 指标何时能预测实际采用与 regret。

Clarification 不是 novelty 主张。[IDRBench](#)、[IntentRL](#)、[DiscoBench](#) 与 [G-STEER](#) 已覆盖 interactive Deep Research、主动澄清、搜索歧义恢复和个性化 Retrieve/Ask/Stop。[\[2\]](#) [\[3\]](#) [\[4\]](#) [\[5\]](#) DeepAlign 的新意必须来自 paired-user estimand、非补偿测量和能改变系统结论的 judge stress test，而不是“我们也允许 agent 提问”。

9. 五天冻结与执行计划

[ICLR 2027 Author Guidelines](#) 当前给出的摘要截止为 2026-09-18 AOE、全文截止为 2026-09-25 AOE。[\[6\]](#) 从 2026-08-14 起约剩 35/42 天。因此最迟仍应在 8 月 17 日冻结 thesis、最近邻边界、主指标 profile、family 原语和 go/no-go 证据。

五天内必须完成：解除 GPT-5 合规访问阻塞并复现现有 artifacts；完成两名盲化人评；确认至少 2 个 family 的 paired-user 真值稳定；冻结主统计和反例定义。若 8 月 17 日前仍无 GPT-5/真人复现，应停止“PDR false-positive”强 claim，改做更窄的 personalization judge validity，或换题。

两个月的资源上限固定为优先完成 12 个端到端 family (5 DR / 3 Software / 4 Data)，不运行 60×多用户×多条件×多系统的笛卡尔积。三个 vertical 各先完成环境 reset、invariant verifier 和 matched/swapped pilot；效用子集数量由功效模拟冻结。

参考文献

- [1] [Towards Personalized Deep Research: Benchmarks and Evaluations](#). ICLR 2026.
- [2] [IDRBench](#). 2026.
- [3] [IntentRL](#). 2026.
- [4] [DiscoBench](#). 2026.
- [5] [G-STEER](#). 2026.
- [6] [ICLR 2027 Author Guidelines](#). 2026.