

HUMAN STUDY INSTRUMENT · CREDAMO BUILD GUIDE

# DeepAlign-Bench

## 真人 Task-conditioned Persona 三轮问卷方案

Consent · Screening · Routing · Open-first Elicitation · Human Confirmation

|      |                                                  |
|------|--------------------------------------------------|
| 文档版本 | v0.56 · 可搭建草案                                    |
| 日期   | 2026 年 8 月 20 日                                  |
| 研究主线 | Wave A：筛选与候选任务 · Wave B：开放先行深<br>采 · Wave C：逐条确认 |

### 核心命题

不让参与者直接编 persona；只从真实相关任务出发，把开放原话经来源约束的规范化和本人确认转化为后台 ledger。

## 内容导航

1. 设计结论与 21 页流程
2. Consent 与 participant screening
3. 60-task relevance routing 与选择
4. 开放题、通用 schema 与三类任务 schema
5. LLM fact-card confirmation
6. 质控、时长、报酬与后台字段
7. Reviewer attacks、pilot 与上线门

使用方式：先锁定三轮结构，再按题号录入 Credamo；任何正式招募必须先通过伦理审查、平台功能核验和 20-30 人 soft launch。

## 1. 设计结论

本问卷服务于 Personalized Long-Horizon Knowledge Work Benchmark。候选池包含 60 个预定义 task family：24 个 Deep Research、18 个 Software Engineering、18 个 Data Analysis / ML / Spreadsheet。目标不是让参与者“编一个 persona”，而是从参与者确实可能遇到的具体任务出发，获得经本人确认的 **task-conditioned user ledger**：与这个任务有关的目标、知识、约束、权衡、风险、受众、环境、权限和不可接受结果。

问卷必须保持以下顺序：

1. 参与者先判断任务是否与现实需要有关；
2. 对进入深度采集的任务，先回答开放问题；
3. 开放答案提交并保存初始版本后，才显示结构化补充问题；
4. LLM 只能把原话抽取成候选事实，不能增加事实；
5. 参与者逐条批准、修改、删除或标记不确定，才形成 ledger。

推荐使用三个相互链接的 Credamo 问卷，而不是把所有步骤塞进一次长问卷：

- **Wave A：筛选、路由与候选任务选择，10-15 分钟。** 用户从适配的 task cards 中选 3-5 个真实相关的候选任务。
- **Wave B：任务条件化 elicitation，每个任务 15-22 分钟。** 后台综合真实相关度、经验、安全可回答性和覆盖缺口，为每人分配 1 个主任务，最多再分配 1 个次任务。
- **Wave C：LLM 规范化确认，每个任务 5-8 分钟。** 离线生成候选 ledger，再回访同一参与者逐条确认。

Credamo 官网公开说明平台支持在线随机实验设计、多期追踪和配对调查，因此三轮结构在产品定位上是合理的；但稳定匿名 ID、预填事实卡、动态配额、页面时间戳和外部 API 等具体功能仍须在正式建问卷时逐项核实。[Credamo 官方网站](#) 中国《科技伦理审查办法（试行）》明确把以人为调查对象以及使用个人信息数据的科技活动纳入伦理审查范围，并要求审查招募公平性、补偿、隐私、知情同意和数据治理。本项目不得把页脚提示当成伦理审批替代。[科技伦理审查办法（试行）](#)

## 2. Credamo 页面总表

| 页面 | Part | 页面目的                    | 主要输出                        | 预计时间    | 进入条件      |
|----|------|-------------------------|-----------------------------|---------|-----------|
| A0 | 0    | 研究说明                    | 未采集数据                       | 1 min   | 打开 Wave A |
| A1 | 0    | 年龄与知情同意                 | consent record              | 1-2 min | 全部参与者     |
| A2 | 1    | 基础人口学与当前身份              | minimal demographics        | 2 min   | 同意且 ≥18 岁 |
| A3 | 1    | 教育、职业和领域                | role/domain profile         | 2-3 min | A2 完成     |
| A4 | 1    | Coding/Data/Research 经验 | vertical capability profile | 2-3 min | A3 完成     |

| 页面    | Part | 页面目的                    | 主要输出                            | 预计时间         | 进入条件                             |
|-------|------|-------------------------|---------------------------------|--------------|----------------------------------|
| A5    | 2    | 近一年及未来任务经历              | route profile                   | 1-2 min      | A4 完成                            |
| A6    | 2-3  | 展示 10-15 张适配 task cards | offered-task log                | 3-5 min      | 至少一个 vertical 可路由                |
| A7    | 3    | 选择 3-5 个候选任务            | candidate selections            | 2 min        | 至少 3 个 task 通过相关性门；否则选 1-2 或正常结束 |
| A8    | 3    | 候选任务真实性核验               | scenario snippets               | 3-6 min      | 对每个已选 task 循环                    |
| A9    | 0/3  | 回访授权与结束                 | recontact permission            | 1 min        | Wave A 完成                        |
| B0    | 4    | 回访说明和 assigned task 确认  | task assignment acknowledgement | 1 min        | 被邀请进入 Wave B                     |
| B1    | 4    | Open-first elicitation  | frozen open-response snapshot   | 5-8 min/task | 每个 assigned task                 |
| B2    | 4    | 全任务通用补充                 | global structured facts         | 3-5 min/task | B1 已提交                           |
| B3-DR | 4    | Deep Research schema    | DR prompted facts               | 4-7 min/task | task.vertical=DR                 |
| B3-SW | 4    | Code schema             | software prompted facts         | 4-7 min/task | task.vertical=SW                 |
| B3-DA | 4    | Data schema             | data prompted facts             | 4-7 min/task | task.vertical=DA                 |
| B4    | 4    | 原始回答回看                  | correction log                  | 1-2 min/task | vertical module 完成               |
| C0    | 5    | 解释 LLM 规范化              | confirmation consent            | 1 min        | Wave B 已规范化                      |
| C1    | 5    | 逐条 fact card 审核         | approved/edited/deleted facts   | 4-7 min/task | 每个 candidate fact                |
| C2    | 5    | Ledger 总览和遗漏检查          | final user-confirmed ledger     | 1-2 min/task | fact cards 完成                    |
| C3    | 5    | 结束与撤回说明                 | completion status               | 1 min        | Wave C 完成                        |

## 单次问卷备选

如果必须一次完成，则可以让参与者对 3-5 个任务均走 Part 4，但预计总时长约 55-100 分钟，必须提高报酬、允许中断续答，并预期明显更高的 attrition。该版本不建议作为首发。

### 3. Part 0 : Consent 和研究说明

#### A0 研究说明页

参与者看到的文本：

> 欢迎参加“AI 长程知识工作需求”学术研究。本研究希望了解：当 AI 帮助不同用户完成研究、软件开发或数据分析任务时，哪些与具体任务有关的目标、背景、限制和偏好会影响一个真正可用的结果。 >> 本研究不会要求你现在完成这些复杂任务，也不会要求你编写“人物设定”。你只需要判断哪些任务在现实中与你有关，并描述你在这些具体任务中的真实使用情境。 >> 请不要填写姓名、单位名称、客户名称、账号、密码、内部代码、未公开数据或其他机密内容。遇到涉及工作或个人隐私的情况，请使用泛化描述，例如“某电商团队”或“某高校实验室”。 >> 研究分为最多三次：第一次约 10-15 分钟；如你的任务与研究需要匹配，第二次每个任务约 15-22 分钟；第三次每个任务约 5-8 分钟，用于确认系统是否准确理解了你的原始回答。是否进入后续回访不影响本次已完成部分的报酬。

本页只呈现说明，不记录滚动、停留或鼠标轨迹，除非伦理方案另行批准。

#### A1 年龄与知情同意

##### C01 年龄资格

- 题目文本： 你是否已年满 18 周岁？
- 题型： 单选，必答
- 选项： 是；否
- 跳转： 选择“否”→显示感谢和不符合资格说明→结束；不得继续收集人口学或开放文本。
- 变量： `consent.adult_18_plus`

##### C02 研究参与同意

- 题目文本： 阅读以上说明后，你是否自愿参加本研究？你可以随时退出；退出不会受到惩罚，已获得的合法报酬不因退出被追回。
- 题型： 单选，必答
- 选项： 我同意参加；我不同意参加
- 跳转： 不同意→结束。
- 变量： `consent.participate`

##### C03 LLM 规范化说明确认

- 题目文本： 研究团队可能使用经批准的语言模型，把你的原始回答整理成候选事实卡。模型不会自动成为最终答案；你将在后续页面逐条批准、修改或删除。你是否理解并同意这一处理方式？
- 题型： 单选，必答
- 选项： 理解并同意；不同意使用语言模型处理我的回答
- 跳转： 不同意→如果研究团队提供纯人工规范化分支，则进入人工分支；否则结束。不得把“同意参加研究”推定为“同意外部模型处理”。
- 变量： `consent.llm_normalization`

## C04 去标识化研究使用

- 题目文本： 你是否同意研究团队在去除直接身份信息后，将经你确认的任务相关事实用于学术分析和 benchmark 构建？原始开放回答和完整私有 ledger 默认不公开。
- 题型： 单选，必答
- 选项： 同意；不同意
- 跳转： 不同意→结束或进入仅用于内部方法试测、不得纳入正式 benchmark 的分支，须依伦理批件决定。
- 变量： `consent.deidentified_research_use`

## C05 后续回访意愿

- 题目文本： 如果本次回答与某些任务匹配，你是否愿意通过 Credamo 接收 1-2 次后续邀请？是否愿意不影响本次报酬。
- 题型： 单选，必答
- 选项： 愿意；暂时不确定；不愿意
- 跳转： 不愿意仍可完成 Wave A，但不进入需要本人确认的正式 ledger；数据只能用于筛选率和问卷开发分析。
- 变量： `consent.recontact`

## C06 理解检查

- 题目文本： 以下哪项最准确描述你在本研究中的任务？
- 题型： 单选，必答
- 选项： A. 现在替研究团队完成所有复杂任务；B. 描述与具体任务有关的真实需求，并核对系统整理是否准确；C. 根据想象编写一个尽量戏剧化的人设；D. 给 AI 产品做广告评价
- 正确选项： B
- 处理： 首次错误时展示说明并允许重答；第二次错误记 soft flag，不单独自动排除。
- 变量： `qc.consent_comprehension`

# 4. Part 1 : Participant Screening

## A2 基础人口学与当前身份

人口学只用于描述样本和公平性审计，不参与 task routing，除成年资格外不得作为展示任务的输入。

### D01 年龄段

- 文本： 你的年龄段是？
- 题型： 单选，必答
- 选项： 18-24；25-34；35-44；45-54；55-64；65 岁及以上；不愿回答
- 逻辑： 不参与路由。

## D02 性别

- 文本： 你的性别是？
- 题型： 单选，选答
- 选项： 女；男；非二元/其他；不愿回答
- 逻辑： 不参与路由。

## D03 常住地区

- 文本： 你目前主要居住在哪个地区？
- 题型： 单选，必答
- 选项： 中国大陆；中国香港/澳门；中国台湾；亚洲其他地区；欧洲；北美；其他；不愿回答
- 逻辑： 只用于语言、法规和样本描述；涉及地域任务时必须再问 task-specific 情境，不能直接从地区推断需求。

## D04 主要使用语言

- 文本： 你在学习或工作中最常使用哪些语言？
- 题型： 多选，必答
- 选项： 中文；英文；德语；法语；日语；韩语；西班牙语；其他（填写）；不愿回答
- 逻辑： 可用于多语言/跨国 task 的最低语言可读性匹配。

## D05 当前主要身份

- 文本： 你当前最主要的身份是？
- 题型： 单选，必答
- 选项： 本科生；硕士生；博士生；高校/科研人员；企业全职；企业兼职/实习；自由职业/个体经营；创业者；暂未就业；退休；其他（填写）

## A3 教育、职业和领域

### B01 最高教育程度

- 文本： 你的最高学历或当前正在攻读的学历是？
- 题型： 单选，必答
- 选项： 高中/中专及以下；大专；本科；硕士；博士；其他；不愿回答

### B02 学科或专业领域

- 文本： 你接受过系统学习或训练的领域有哪些？请选择所有适用项。
- 题型： 多选，必答；选项随机化，“其他/无”固定在末尾

- 选项： 计算机/软件工程；人工智能/机器学习；数据科学/统计；数学/物理；材料/化学；生命科学/医学；心理/教育；经济/金融/会计；工商管理/市场/产品；法律/公共政策；环境/能源/地理；建筑/房地产；新闻/传播/创意写作；其他（填写）；无以上系统训练
- 变量： `profile.education_domains[]`

### B03 当前或最近职业领域

- 文本： 你当前或最近一份学习/工作的主要行业或场景有哪些？
- 题型： 多选，必答
- 选项： 高校/科研；互联网/软件；人工智能；金融/支付/保险；零售/电商；制造/供应链；医疗健康；教育；政府/公共事业；能源/环保；咨询/专业服务；媒体/出版/创意；房地产；旅游/差旅；非营利组织；其他；暂无相关经历
- 变量： `profile.occupation_domains[]`

### B04 工作职能

- 文本： 你实际承担过哪些工作或学习职能？
- 题型： 多选，必答
- 选项： 软件开发；测试/运维/SRE；数据分析/商业分析；数据工程；机器学习/建模；学术研究/文献综述；产品管理/用户研究；经营/战略/咨询；财务/会计/投资；市场/销售；教育/培训；法律/合规/风控；设计/内容创作；管理决策；其他；暂无
- 变量： `profile.functions[]`

### B05 相关经历年限

- 文本： 在你最熟悉的上述领域中，你累计有多少年实际学习、研究或工作经历？
- 题型： 单选，必答
- 选项： 不足 6 个月；6-12 个月；1-2 年；3-5 年；6-10 年；10 年以上

### B06 决策责任

- 文本： 在相关任务中，你通常承担什么责任？
- 题型： 多选，必答
- 选项： 自己使用结果；准备材料供他人决定；提出建议；共同决策；对最终决定负责；负责实现/维护交付物；仅学习或观察；其他

## A4 Coding / Data / Research 经验

### E01 三类工作的实际频率

- 文本： 过去 12 个月，你实际做过以下工作多少次？
- 题型： 矩阵单选，必答



- 行： 查找并综合多来源资料；修改或构建跨文件软件项目；使用表格/SQL/Python 完成数据分析；训练或评估机器学习模型；制作需要他人采用的复杂报告/决策材料
- 列： 从未；1-2 次；3-5 次；6-11 次；每月至少一次；每周至少一次

## E02 Coding 熟练度

- 文本： 你目前独立完成软件开发或代码调试任务的能力最接近哪一项？
- 题型： 单选，必答
- 选项： 没有相关经验；能阅读少量代码但不能独立修改；能完成脚本或单文件程序；能在已有项目中修改并测试；能负责跨文件/部署/架构任务；不愿回答

## E03 Coding 技术

- 文本： 你实际使用过哪些技术？
- 题型： 多选；仅 E02#没有经验时显示
- 选项： Python；JavaScript/TypeScript；Java/Kotlin；C/C++；R；SQL；Web/backend framework；测试框架；容器/云；CI/CD；分布式系统；安全工具；其他

## E04 Data 熟练度

- 文本： 你目前独立完成数据分析或建模任务的能力最接近哪一项？
- 题型： 单选，必答
- 选项： 没有相关经验；能阅读图表和基础统计；能使用电子表格完成分析；能使用 SQL/R/Python 完成可复现分析；能负责建模、实验或数据产品；不愿回答

## E05 Data 工具

- 文本： 你实际使用过哪些数据工具或方法？
- 题型： 多选；仅 E04#没有经验时显示
- 选项： Excel/Sheets；SQL；Python；R；BI 工具；统计建模；机器学习；A/B test；因果推断；地理空间分析；数据工程；其他

## E06 Research 熟练度

- 文本： 你目前独立完成多来源研究任务的能力最接近哪一项？
- 题型： 单选，必答
- 选项： 没有相关经验；能搜索并整理一般资料；能比较多个来源并核对引用；能完成系统文献/市场/政策研究；能设计检索策略并审计证据质量；不愿回答

## E07 AI 委托经历

- 文本： 过去 12 个月，你是否把以下任务交给过 AI 工具协助？
- 题型： 多选，必答

- 选项：深度资料检索/报告；代码开发或调试；数据分析/表格；机器学习；决策建议；未使用过；其他

## 5. Part 2 : Task Relevance Routing

### A5 最近与预期任务经历

#### R01 三个 vertical 的现实相关性

- 文本：在未来 12 个月，你现实中可能需要完成哪些类型的工作？
- 题型：多选，必答
- 选项：多来源检索、比较和报告；修改/构建真实软件项目；分析真实数据或工作簿；训练/评估模型；以上都不太可能；不确定

#### R02 可安全描述性

- 文本：如果任务涉及学习或工作，你是否能在不提供机密信息、个人身份信息、内部数据或代码的情况下描述自己的需求？
- 题型：单选，必答
- 选项：可以；需要把具体名称和数字泛化后可以；大多数情况下不可以；不确定
- 逻辑：“大多数情况下不可以”不自动排除，只展示明显可以从个人经历回答的低敏任务；具体 task 仍单独确认。

#### R03 领域情境

- 文本：你现在或未来一年中，最可能需要 AI 协助的领域有哪些？
- 题型：多选，必答
- 选项：学术申请/科研；AI/软件产品；职业/国际流动；创作/出版；住房/消费决策；家庭/教育；健康信息；投资/金融；法律/政策/合规；材料/工业研发；环境/能源/公共事业；旅游/差旅；零售/营销/产品增长；财务/经营；制造/供应链；其他；暂时没有

### 路由算法

1. 硬过滤：只使用教育领域、职业领域、实际职能、Coding/Data/Research 能力、R01-R03 和 task-specific 安全可回答性；不得使用性别或年龄段。
2. 候选池：vertical 能力或领域情境至少一项匹配。对专业工作任务，不能只凭“感兴趣”进入；个人决策任务可以由真实决策角色满足相关性。
3. Slate 规模：每人优先展示 10-15 张，而不是 60 张。
4. 构成：约 8 张强匹配、2 张可迁移能力匹配、2 张当前覆盖不足但仍满足资格的任务；若合格任务较少则不补无关任务。

5. 顺序：在 match tier 内随机；记录每张卡的展示顺序、展开和回答。
6. 探索入口：提供“查看其他任务”，但额外任务仍须通过 relevance/experience/safe-answerability 门。
7. 后台覆盖奖励：只在多个任务同样适合该参与者时，用 coverage deficit 打破并列；不得为了配额把低相关任务分配给用户。

推荐评分只用于排序，不直接构成 gold：

```
route_score = real_relevance(0-4) + experience(0-3) + safe_answerability(0-1) +
vertical_capability(0-2) + domain_match(0-2) + eligible_coverage_bonus(0-2)。
```

## 6. Part 3 : Task Selection

### A6 每张 task card 的展示格式

每张卡只显示中性的任务壳，不显示研究者预想的 personalization axes，不暗示应该有哪些用户差异。

> 任务标题 >> 情境：用 1-2 句话说明给定材料和要完成的工作。 >> 可能交付：报告 / 代码修改 / notebook / workbook / 决策备忘录等。 > 你现在不需要完成任务，只需判断它是否与你的现实情况有关。

### 每张已展示卡的题目

#### TREL relevance check

- 文本：这项任务与你的现实需要有多大关系？
- 题型：单选，必答
- 选项：我目前正在面对类似任务；过去 12 个月做过类似任务；未来 12 个月很可能需要；只是感兴趣或可以想象；与我无关/无法判断
- eligible：前三项。

#### TEXP experience check

- 文本：对这类任务，你最接近哪种情况？
- 题型：单选，必答
- 选项：曾对类似任务的结果负责；曾实际参与类似任务；理解该场景并会使用结果；只听说过；无法判断
- eligible：前三项。高专业门槛任务优先要求前两项；个人决策类任务允许“理解并会使用结果”。

#### TSafe confidentiality check

- 文本：你能否在不透露姓名、单位、客户、账号、内部数据、代码或其他机密内容的情况下，描述自己对这项任务的真实需要？
- 题型：单选，必答
- 选项：可以；泛化细节后可以；不可以；不确定
- eligible：前两项。

## TAI delegation check

- 文本： 如果 AI 能够安全、可靠地完成该任务，你现实中有多大可能把它交给 AI 协助？
- 题型： 5 点单选，必答
- 选项： 非常可能；比较可能；不确定；比较不可能；完全不可能
- 用途： 构造效度和排序；不以“不可能”单独拒付或自动排除。

## A7 候选任务选择

## TSELECT

- 文本： 请从上面通过相关性检查的任务中选择 3-5 个：它们必须是你现实中正在、曾经或很可能需要完成，而且你可能愿意让 AI 协助的任务。请选择“真实相关”，不要只选择看起来有趣的任务。
- 题型： 多选，至少 3、至多 5
- 跳转： 只有 1-2 个任务通过时，允许选择全部并正常结束，不强迫凑 3 个；0 个任务通过时，记录 recruitment non-match 并结束。

## A8 对每个候选任务进行真实性核验

## TAUTH1

- 文本： 请简要描述一个你当前、过去 12 个月或未来一年很可能遇到的具体情境，说明为什么这项任务与你有关。请勿填写单位、客户或个人姓名。
- 题型： 开放文本，必答，建议 30-300 个汉字
- 校验： 少于 30 字提示补充，但允许参与者选择“我无法在不泄密的情况下进一步描述”。

## TAUTH2

- 文本： 如果 AI 完成这项任务，谁会使用它的结果？
- 题型： 多选，必答
- 选项： 我自己；同学/研究合作者；直属团队；管理者/客户；公众/读者；家人；其他；尚不确定

## TAUTH3

- 文本： 得到结果后，你最可能采取什么下一步行动？
- 题型： 开放文本，必答，20-250 个汉字

## A9 回访和 Wave A 结束

## 文本：

> 你已完成第一阶段。研究团队会根据真实相关性、你的经验、安全可回答性和当前任务覆盖情况，从你选出的 3-5 个候选任务中邀请你深入描述 1 个主任务，最多再邀请 1 个任务。没有被邀请不代表你的回答质量有问题，也不影响本次报酬。

不在主数据表直接收集手机号、微信号或邮箱。优先使用 Credamo 匿名样本 ID 和平台回访功能；如必须收联系方式，应进入独立表单和独立数据表。

## 7. Part 4 : Persona Elicitation

### B0 回访说明

> 本次将围绕你先前选择的具体任务展开。请根据自己的真实情况回答，而不是想象一个理想用户。你不需要解决任务本身。开放问题会先出现；后续选择题用于补充可能遗漏的信息。系统会分别记录哪些信息是你主动提到的、哪些是在提示后补充的。

#### B00 情境仍然有效吗

- **文本：** 你之前描述的这项任务目前仍与你有关吗？
- **题型：** 单选，必答
- **选项：** 是，情况基本不变；是，但情况有变化（请说明）；已不再相关；不确定
- **跳转：** 已不再相关→记录 expiry，不强迫继续；可询问是否愿意以过去情境完成，但不得与当前真值混合。

### B1 Open-first：先保存原始事实

本页提交前不得显示后续 schema。若 Credamo 允许返回上一页，应保存首次提交版本；任何在看到 schema 后的修改另记 `prompted_contaminated`，不能覆盖 spontaneous provenance。

#### O01 具体使用情境

- **文本：** 请更具体地描述：在什么情况下你会需要 AI 完成这项任务？当时你要解决什么问题或作出什么决定？
- **题型：** 开放文本，必答，建议 80-800 个汉字

#### O02 最终成果和下一步行动

- **文本：** 你希望 AI 最终交付什么？谁会使用它？得到结果后，你或团队下一步会做什么？
- **题型：** 开放文本，必答，建议 60-600 个汉字

#### O03 会改变好答案的现实条件

- **文本：** 哪些与你本人、团队、已有资源、使用环境或当前状态有关的情况，会改变什么才算一个好结果？如果你认为没有，也请说明。
- **题型：** 开放文本，必答，建议 60-600 个汉字

#### O04 不可接受的结果

- **文本：** 什么样的结果即使看起来专业，对你来说仍然无法使用或可能造成损失？为什么？
- **题型：** 开放文本，必答，建议 50-500 个汉字

#### O05 AI 应该追问什么

- **文本：** 如果 AI 在开始前只能再问你几个问题，它最应该先确认什么？如果不需要追问，可以填写“无需追问”。
- **题型：** 开放文本，必答，0-400 个汉字

## B2 全任务通用 schema

所有题都提供“不确定 / 没有偏好 / 不适用 / 不愿回答”，以免提示本身制造虚假偏好。

### G01 使用目的

- 文本： 这项成果最主要用于什么？
- 题型： 单选 + 其他
- 选项： 个人选择；团队决策；正式提交/发表；执行或部署；探索学习；向他人解释；风险审查；其他；尚不确定

### G02 受众

- 文本： 最终成果需要让哪些人读懂或使用？
- 题型： 多选
- 选项： 非专业个人；具有一般业务背景的人；技术人员；领域专家；管理决策者；监管/审查人员；只供自己；其他；尚不确定

### G03 你对该任务的已有知识

- 文本： 在这项具体任务上，你目前的知识和准备程度如何？
- 题型： 5点单选
- 选项： 几乎不了解；了解基本概念；能判断常见方案；能独立完成部分工作；能审查专家级成果；不确定/不愿回答

### G04 时间窗口

- 文本： 如果这是真实任务，你通常需要在多久内获得可用结果？
- 题型： 单选
- 选项： 当天；2-3天；一周；2-4周；1-3个月；没有固定期限；其他

### G05 资源边界

- 文本： 哪些资源限制会影响方案？请选择所有适用项。
- 题型： 多选
- 选项： 预算；人力；计算资源；可访问数据；可使用软件/云服务；法律/合规；组织审批；时间；没有明确限制；其他

### G06 硬约束

- 文本： 请列出违反后会使结果直接不可用的硬约束。若没有明确硬约束，请填写“无”。
- 题型： 开放文本，必答，0-400字

## G07 可接受替代

- 文本： 如果最佳方案不可行，你可以接受哪些替代或折中？哪些方面可以灵活，哪些不能？
- 题型： 开放文本，必答，0-400 字

## G08 结果形式

- 文本： 哪些交付形式对你最有用？
- 题型： 多选
- 选项： 简短结论；详细报告；可执行步骤；比较表；代码/patch；notebook；电子表格；图表/dashboard；引用和证据清单；风险/假设日志；其他；无偏好

## G09 权限边界

- 文本： AI 在完成任务时不应做哪些事情？
- 题型： 多选 + 开放
- 选项： 上传内部数据；调用外部云服务；新增付费依赖；修改生产环境；替我作最终高风险决定；披露个人/组织信息；访问未授权来源；没有额外限制；其他

## G10 风险态度

- 文本： 当证据不充分时，你更希望 AI 怎么做？
- 题型： 单选
- 选项： 停止并说明缺口；先追问我；给出多个条件分支；给出保守建议并明确不确定性；在合理假设下继续；取决于具体情况；无偏好

## B3-DR Deep Research schema

### DR01 研究目标

- 文本： 这项研究最重要的作用是什么？
- 题型： 多选，最多 3 项
- 选项： 形成推荐/选择；了解研究或市场全景；核对某项主张；寻找数据集/资源；查找先前技术；处理冲突证据；获得最新变化；尽可能完整地枚举对象；形成行动计划；其他

### DR02 既有工作

- 文本： 你已经做过哪些准备？
- 题型： 多选 + 开放
- 选项： 尚未开始；做过普通搜索；读过若干关键资料；已有候选方案；已有内部材料；咨询过他人；其他

### DR03 研究范围

- 文本： 哪些范围必须限制或覆盖？例如地域、时间、语言、行业、人群、技术版本。

- 题型： 开放文本，必答，可填“无明确限制”

#### DR04 来源要求

- 文本： 你对信息来源有什么要求？
- 题型： 多选
- 选项： 官方文件优先；同行评审论文优先；原始数据优先；行业/公司材料可以使用；新闻可以作为线索；社区/论坛可以作为线索；必须能公开访问；可以使用付费来源；无偏好；其他

#### DR05 新鲜度

- 文本： 信息需要新到什么程度？
- 题型： 单选
- 选项： 必须是最近一个月；最近一年；最近三年；经典资料也重要；取决于子问题；无明确要求

#### DR06 广度与深度

- 文本： 在时间有限时，你更倾向于？
- 题型： 5点语义差异量表
- 端点： 尽量广泛覆盖 ↔ 少量关键对象深入核验

#### DR07 决策标准

- 文本： 最终比较或推荐时，哪些标准最重要？请选择最多 5 项，再选出最重要的 1 项。
- 题型： 多选 + 后续单选
- 选项： 成本；效果；证据可信度；适用性；时间；风险；可逆性；维护难度；合规；可获得性；公平性；创新性；其他

#### DR08 漏掉与误收的权衡

- 文本： 如果无法同时避免，你更担心哪种错误？
- 题型： 5点语义差异量表
- 端点： 漏掉真正重要的选项/证据 ↔ 纳入未经充分验证的选项/证据

#### DR09 建议阈值

- 文本： 证据存在明显冲突时，AI 应做到什么程度才可以给出行动建议？
- 题型： 单选
- 选项： 只报告冲突，不建议；提出需要补充的信息；给条件化建议；给保守建议；仍给明确首选并说明风险；取决于决策可逆性；无偏好



## B3-SW Code / Software Engineering schema

### SW01 技术栈

- 文本： 如果这是你的真实项目，请描述必须兼容的语言、框架、库和版本。若没有固定栈，请写“无固定栈”。
- 题型： 开放文本，必答

### SW02 运行与部署环境

- 文本： 代码最终在哪里运行？
- 题型： 多选 + 开放
- 选项： 本地电脑；服务器；容器/Kubernetes；公有云；移动端；浏览器；嵌入式/边缘；科研计算环境；暂未确定；其他

### SW03 兼容性

- 文本： 对向后兼容和公开 API，你的要求是什么？
- 题型： 单选
- 选项： 绝不能破坏现有调用；允许弃用但需迁移期；可以做小范围 breaking change；原型阶段可重构；不适用/不确定

### SW04 依赖政策

- 文本： 是否允许增加新依赖或外部服务？
- 题型： 单选 + 条件开放
- 选项： 不允许；仅允许现有生态中的轻量依赖；允许但需说明许可证/维护风险；允许托管服务；取决于收益；无偏好

### SW05 维护者环境

- 文本： 谁将长期维护代码？他们最熟悉什么？
- 题型： 多选 + 开放
- 选项： 只有我；1-3 人小团队；大型团队；开源贡献者；运维团队；研究人员；初学者；暂不维护；其他

### SW06 测试与回归

- 文本： 你对测试和回归保护的最低要求是什么？
- 题型： 多选
- 选项： 通过现有测试；新增核心单元测试；集成测试；端到端测试；性能基准；安全扫描；跨版本矩阵；只需原型验证；其他

### SW07 性能预算

- 文本： 哪些性能指标会决定实现是否可用？请填写已知阈值；不知道可以写“不确定”。
- 题型： 开放文本

- 提示： 延迟、吞吐、内存、启动时间、模型大小、成本、数据规模。

## SW08 安全与隐私

- 文本： 哪些安全、隐私或权限要求必须满足？
- 题型： 多选 + 开放
- 选项： 不记录敏感数据；最小权限；审计日志；依赖漏洞控制；密钥隔离；数据不得离开本地；合规要求；暂无额外要求；其他

## SW09 发布和回滚

- 文本： 你希望如何上线这个改动？
- 题型： 单选
- 选项： 一次性替换；feature flag；灰度/分阶段；双写/影子模式；仅提交 patch 不部署；需要明确回滚方案；不适用/不确定

## SW10 可维护性交付

- 文本： 除功能代码外，你需要哪些内容？
- 题型： 多选
- 选项： 设计说明；迁移指南；运维说明；注释；示例；benchmark；风险/假设日志；无需额外文档；其他

## B3-DA Data Analysis / ML / Spreadsheet schema

### DA01 决策目标

- 文本： 这项分析最终要支持什么业务、科研或运营决定？谁对决定负责？
- 题型： 开放文本，必答

### DA02 分析类型

- 文本： 你最需要哪类结论？
- 题型： 多选
- 选项： 描述现状；诊断原因；预测未来；比较方案；评估干预效果；优化资源分配；建立持续监控；探索未知模式；其他

### DA03 核心指标

- 文本： 最重要的主指标、辅助指标和不能恶化的 guardrail 指标分别是什么？不知道可以说明需要 AI 帮助定义。
- 题型： 三个短文本框

### DA04 错误成本

- 文本： 哪种错误代价更大？

- 题型： 单选 + 开放解释
- 选项： 误报/错误采取行动；漏报/错过机会；高估；低估；不同人群代价不同；两者接近；无法判断

#### DA05 解释性

- 文本： 使用者需要理解到什么程度？
- 题型： 单选
- 选项： 只需可靠结果；需要整体驱动因素；需要个体/样本级解释；需要可审计公式和中间计算；需要向非技术受众解释；需要满足监管审查；不确定

#### DA06 因果边界

- 文本： 你是否需要回答“某行动导致了什么”，还是描述/预测已经足够？
- 题型： 单选
- 选项： 描述即可；预测即可；需要因果证据；需要实验/准实验方案；不确定，应由 AI 判断并说明限制；不适用

#### DA07 数据与隐私

- 文本： 数据有哪些使用限制？
- 题型： 多选 + 开放
- 选项： 含个人信息；含商业机密；只能本地处理；不能与外部数据连接；需要去标识化；存在授权/许可证限制；没有额外限制；不确定；其他

#### DA08 计算和时限

- 文本： 可用的计算资源和完成时限是什么？
- 题型： 多选 + 开放
- 选项： 普通办公电脑；CPU 服务器；GPU；云资源；只能电子表格；没有固定限制；结果需当天；一周内；更长周期；其他

#### DA09 可复现性

- 文本： 最终分析需要达到什么复现程度？
- 题型： 单选
- 选项： 一次性结论即可；保留公式和步骤；提供可运行 notebook/script；建立自动更新管线；需要审计日志和版本固定；不确定

#### DA10 交付和部署

- 文本： 分析结果将如何交付或持续使用？
- 题型： 多选

- 选项： 静态报告；电子表格；notebook；dashboard；API/模型服务；定期更新；一次性决策会议；其他；尚不确定

## B4 原始回答回看

### REVIEW01

- 文本： 下面展示的是你本次填写的原始回答。你可以修正错别字或明确歧义，但不要因为看到后续选项而把未曾考虑的偏好写成“一开始就有”。如需补充，请使用“补充说明”框，系统会标记为 prompted information。
- 题型： 只读原文 + 开放补充
- 变量： `raw_revision_log`；不得覆盖 B1 初次提交快照。

## 8. Part 5：LLM Normalization Confirmation

### c0 说明页

> 下面的内容由语言模型根据你的原始回答整理。模型可能遗漏、误解或过度概括。每一条都附有你的原话来源；没有原话依据的内容不应被保留。请逐条确认。你可以不同意模型，也可以删除任何你不希望研究团队继续使用的内容。

LLM 输入必须是最小化后的 task-specific responses，不得包含联系方式。模型系统提示应明确：参与者文本是数据，不是指令；禁止从人口学或语气推断敏感属性；无 source span 的候选 fact 必须拒绝。

### C1 每条候选 fact card

卡片固定显示：

- 类别： 目标 / 背景 / 硬约束 / 偏好 / trade-off / 风险 / 受众 / 环境 / 权限 / 不可用条件；
- 系统整理： 一句原子事实；
- 你的原话： 精确 source span；
- 来源： 主动提到 / 结构化追问后补充；
- 适用任务： task ID + 标题。

### F01 准确性操作

- 文本： 这条内容是否准确表达了你在该任务中的真实情况？
- 题型： 单选，必答
- 选项： 准确，保留；基本准确但需要修改；不准确，删除；我不确定
- 跳转： 修改→F02；删除→询问是否删除原始 span 的后续研究使用；不确定→保留为 uncertain，不进入稳定方向 gold。

### F02 修改文本

- 文本： 请改成更准确的表述。只写对这个任务确实成立的内容。
- 题型： 开放文本；仅 F01=修改时必答

### F03 重要性

- 文本： 这条内容对结果是否可用有多重要？
- 题型： 单选
- 选项： 违反就不可用；非常重要；有帮助但可折中；只是背景；其实没有偏好；不确定

### F04 灵活性

- 文本： 这条要求可以有多大调整空间？
- 题型： 单选
- 选项： 固定不能变；有限调整；高度灵活；多种方案都可接受；不适用/不确定

### F05 可接受替代

- 文本： 哪些替代方案仍然可以接受？如果没有或不知道，可以留空。
- 题型： 开放文本，选答

### F06 失效条件和时效

- 文本： 这条事实在什么情况下会失效或需要重新确认？
- 题型： 多选 + 开放
- 选项： 某个日期后；项目阶段变化；预算/资源变化；团队/受众变化；政策/技术变化；目前没有明确失效条件；不确定；其他

### F07 使用和披露权限

- 文本： 请分别选择这条内容可以如何使用。
- 题型： 三行独立单选，不得合并成一次“全同意”
- 行 1： 可用于研究团队后台构造评价标准吗？是/否
- 行 2： 在某些实验条件下，可把去标识化后的意思提供给被测 AI 吗？是/否/需再次确认
- 行 3： 可在公开数据中发布高度概括且去标识化的版本吗？是/否/需查看后确认

## C2 Ledger 总览

### L01 总体准确性

- 文本： 作为“你在这个具体任务中的需求记录”，这份总结整体是否足够准确？
- 题型： 单选
- 选项： 可以确认；需要再修改；仍有重要误解；我不愿继续使用这份总结

### L02 遗漏检查

- 文本： 是否遗漏了任何会真实改变最终决定、实现方案或交付形式的重要因素？
- 题型： 开放文本，必答，可写“没有”

- 处理：新增内容标为 `confirmation_added`，不能伪装成 `spontaneous`。

### L03 过度推断检查

- 文本：是否有任何内容让你觉得系统根据身份、专业、年龄、性别或其他背景做了没有依据的推断？
- 题型：单选 + 开放
- 选项：没有；有（说明）；不确定

### L04 最终确认

- 文本：我确认：保留下来的内容在当前时间点能较准确表达我对该任务的需求；我知道仍可按研究说明申请撤回。
- 题型：单选，必答
- 选项：确认；暂不确认
- 跳转：暂不确认→ledger 状态 `not_confirmed`，不得进入 pair/CDM gold。

## 9. Part 6 : Quality Control

### 9.1 硬排除

只在预注册条件成立时排除：

1. 不同意参与、未满 18 岁；
2. 没有任何 task 同时通过现实相关、最低经验和安全可回答性；
3. 开放文本为空、乱码或与题目完全无关，并经人工复核；
4. 多个信号共同确认重复/欺诈，而不是只凭 IP 或时长；
5. Wave C 中所有事实均未获后台使用许可或最终拒绝确认。

“没有形成明显 A/B 差异”“偏好不强”“同意 LLM 的内容很少”都不是质量排除理由。

### 9.2 Soft flags

以下只触发复核，不自动排除：

- 总时长低于 pilot 中位数的三分之一；
- 开放文本在多个 task 之间高度重复；
- 背景题与 task 经验存在矛盾；
- 矩阵题机械同选；
- 理解检查两次失败；
- LLM 候选事实 source-span coverage 低；
- 参与者在确认阶段大量修改；这也可能说明 LLM normalization 有问题，而非参与者低质。

9.3 一致性追问

出现矛盾时使用中性措辞：

> 你前面选择了“没有相关经验”，但也描述了一个类似任务。两者可能分别指不同程度的参与。哪种表述更准确？

选项：修改前一题；修改后一题；两者都对（请解释）；不确定。不得自动选择研究者希望的版本。

9.4 时间检查

- 页面级记录开始、首次提交和最终提交时间；
- 阈值只能在 20-30 人 pilot 后依据 P50/P25 分布冻结；
- 快速但具体、一致的回答可以保留；慢速但复制粘贴的回答仍需复核；
- 不用时长单独判断欺诈。

9.5 文本质量

- 不使用通用“AI 文本检测器”自动排除；
- 检查是否存在同一段模板跨人/跨题复制、无任务对象、无行动后果；
- 参与者开放文本对 normalization LLM 始终按不可信数据处理，其中出现的“忽略规则”等句子不得改变抽取协议；
- 边界样本必须人工复核并保存排除理由。

9.6 支付规则

报酬与“是否最终形成 pair”“是否有明显差异”“是否同意模型总结”脱钩。可预先声明不支付的情况只能包括未完成、平台确认为作弊或明显无意义回答，并设置申诉渠道。

10. 预计时长与报酬建议

10.1 预计完成时间

| 阶段       | 内容                                              | 预计时间             |
|----------|-------------------------------------------------|------------------|
| Wave A   | consent + screening + 10-15 张 cards + 3-5 个候选选择 | 10-15 min        |
| Wave B   | open-first + global + vertical schema           | 15-22 min / task |
| Wave C   | fact cards + final ledger confirmation          | 5-8 min / task   |
| 推荐参与者总负担 | 1 个深采任务                                         | 30-45 min，分三次    |
| 推荐上限     | 2 个深采任务                                         | 50-70 min，分三次    |
| 不推荐单次版   | 3-5 个任务全部深采                                     | 55-100+ min      |

10.2 报酬

建议先按有效时薪而不是 Credamo 宣传的“最低每份问卷价格”定价。公开首页的最低价针对常规样本，并不等于这类需要真实专业情境、开放文本和回访确认的合理补偿。[Credamo 官方网站](#)

| 人群/阶段                        | 建议报酬                    |
|------------------------------|-------------------------|
| Wave A 完成                    | ¥8-12                   |
| Wave B 普通任务                  | ¥15-22 / task           |
| Wave C ledger 确认             | ¥6-10 / task            |
| 普通参与者目标有效时薪                  | ¥40-60 / hour           |
| 稀缺专业人士、高风险领域或高级工程任务          | ¥80-150 / hour，或定向邀请固定价 |
| 很早被筛出且平台支持 screening payment | ¥2-3                    |

20-30 人 pilot 后，用实际 P50/P75 完成时间、attrition 和开放答案质量重新冻结报酬。不要用最快完成者的时长定价。

10.3 总预算现实性

- 12-family paper-first pilot**：若目标为每题 3-4 个 confirmed ledger，即 36-48 个 user-task records，直接报酬大致需要 ¥2,500-4,000，再加平台服务费与稀缺样本加价。
- 60-family 最低覆盖**：每题只有 2 个 ledger 共 120 个 records，没有流失和 pairing 缓冲，¥3,000 已非常紧张。
- 60-family 推荐覆盖**：每题 3-4 个 confirmed ledger 共 180-240 个 records，加上筛选池、三轮 attrition、专业长尾和平台费用，建议先按 ¥8,000-15,000 直接报酬区间规划，再用 pilot 修正。

这些是规划区间，不是统计功效结论；最终人数须由 route 命中率、task coverage、participant clustering 和后续 matched/swapped 终点的方差决定。

11. 后台数据结构和跳转实现

11.1 主键

- `participant_id`：Credamo 匿名 ID 或研究生成的随机 ID；
- `wave_id`：A/B/C；
- `task_id`：60-task pool 中稳定 ID；
- `questionnaire_version`、`routing_version`、`task_card_version`、`normalizer_version`；
- 联系方式若必须收集，使用独立 linkage 表，不进入 persona 数据。



## 11.2 必留漏斗

recruited → consented → screened → offered → relevance-eligible → selected-candidate → assigned → elicitation-complete → normalized → ledger-confirmed → pairable → CDM-qualified。

Dashboard 不能只显示每题 0/1/2 人；至少分别显示 offered、eligible、confirmed、pairable 和 CDM-qualified。

## 11.3 Credamo 跳转

1. 未成年/不同意→结束；
2. 根据 B02-B04、E01-E07、R01-R03 进入 vertical/domain branch；
3. 每个 branch 调用 `routing_matrix.jsonl` 选择 10-15 个 cards；
4. 只有 task-level TREL/TEXP/TSAFE 通过的卡进入 TSELECT；
5. TSELECT 允许 3-5；若合格 task 少于 3，不强迫凑数；
6. Wave B 只循环后台 assigned 的 1-2 个 task；
7. B1 提交后才能进入 B2/B3；
8. Wave C 每条事实循环 F01-F07；F01=删除时不再问重要性，只处理删除/权限；
9. L04 未确认→不得进入正式 ledger。

## 11.4 上线前必须在 Credamo 实机验证

- 分支逻辑、随机 block、跨 wave participant ID；
- 是否能导入或预填不同参与者的 fact cards；
- task 配额和 undercoverage routing 是否可实时更新；
- 页面级时间戳和首次提交快照；
- 手机端长文本保存与恢复；
- 导出后中文、选项编码、missing/declined 区分；
- 若以上任一高级功能不稳定，改为导出 Wave A/B → 本地离线路由/规范化 → 创建定向 Wave B/C 链接，不在 Credamo 中嵌未经批准的外部脚本。

## 12. 上线门和 reviewer attacks

1. “用户自选任务产生 selection bias。”保存 offered/exposure/eligible/selected 全漏斗，主张限制在 task-relevant population。
2. “路由算法为了覆盖强迫无关用户。”coverage bonus 只打破同等资格任务；相关性门优先。
3. “Schema 制造偏好。”开放问题首次提交快照；后续事实标 prompted；提供无偏好/不适用。

4. “只保留可区分 persona。” Pairing 前独立判定 relevance；保留 contrast、near 和 neutral。
5. “LLM 仍在创造 gold。” 无 source span 的 fact fail closed；逐条本人确认；模型 authority=0。
6. “自述偏好不稳定。” 保存时间戳、失效条件、uncertain/alternative，并对 subset 做 test-retest。
7. “问卷太长导致低质。” 3-5 只是候选选择；深采限制为 1-2 个 task，分三轮并按时间支付。
8. “报酬诱导用户夸大相关性。” 报酬不以入 pair、形成差异或研究者主观有效性为条件。
9. “专业题用户没有资格。” 使用真实角色/经历和 task-specific experience gate，而非可刷的知识测验；技术事实另由 domain expert 审计。
10. “隐私和伦理只是形式。” IRB/伦理状态、处理者、存储、撤回和 LLM 数据路径是招募硬门；原始 ledger 默认不发布。

## 13. 最小 pilot

正式招募前先做：

1. 5-8 人认知访谈，逐页询问他们如何理解题意，检查术语、诱导和隐私顾虑；
2. 20-30 人软启动，至少覆盖 DR/SW/DA 各 5 人；
3. 检查 route precision：被展示任务中多少被认为真实相关；
4. 检查 burden：Wave A/B/C 的 P50/P75 时长和退出页面；
5. 检查 spontaneous→prompted 增量，确认 schema 不是主要“制造”偏好的来源；
6. 检查 LLM source-span precision、用户修改/删除率和 stereotype report；
7. 检查任务 coverage，不通过时先调整 routing/tag，而不是降低 relevance gate；
8. 冻结正式版本、报酬、soft-flag 阈值和排除规则，再开始主数据收集。

## 14. 交付映射

- 机器协议：`benchmark_schema/credamo_persona_collection.protocol.yaml`；
- 页面与完整题库：本文件；
- 60-task 路由与中性 task cards：`data/credamo_persona_survey_v0_56/routing_matrix.jsonl`、`task_cards.jsonl`；
- 机器可读题库：`data/credamo_persona_survey_v0_56/question_bank.json`；
- 校验与哈希：同目录 `validate_credamo_survey.py`、`manifest.json`。