

ADVISOR BRIEF

# DeepAlign-Bench | 汇报精简版

15-20 分钟讲清研究问题、方法、实验与两个月范围

导师汇报 · 组会讲解 · 决策讨论

|      |                             |
|------|-----------------------------|
| 文档版本 | v0.20 · 汇报精简版               |
| 日期   | 2026 年 8 月 3 日              |
| 研究主线 | 问题 → 数据 → 实验 → 评分 → 风险 → 决策 |

核心命题

在已有单用户绝对适配之上，测同一任务下哪份结果更适合哪位用户，以及结论能否跨 cue 保持。

## 内容导航

1. 评测对象与核心反事实
2. Task 与 Persona 构建
3. 核心实验矩阵
4. Rubric、Metrics 与 Judge
5. 结果/过程边界
6. 论文贡献
7. 八周安排
8. 导师决策与主要风险

*建议讲法：2 分钟问题、4 分钟数据、4 分钟实验与指标、3 分钟 Judge、3 分钟风险和导师决策。*

## 研究概要

### 一句话问题

已有工作已经测到用户理解、历史利用、工具行动、动态记忆和个性化 Deep Research。我们要补的不是又一块能力，而是一个结果识别问题：同一任务和证据下，agent 能不能为不同用户交付不同但都正确、且各自更适合目标用户的 Deep Research 结果。

### 为什么需要新的 benchmark

个性化评价已经经历三步。第一，Setoka、PersonaTrail/APeB 证明 agent 的用户信号可以来自异构记录、浏览轨迹与行为历史；[\[9\]\[11\]\[15\]](#) 第二，ETAPP 与 Mem2ActBench 已把这些信号落实到工具选择和参数，PAHF 还加入澄清、反馈和偏好漂移。[\[16\]\[19\]\[18\]](#) 第三，PDR-Bench 和另一项 PDR 工作已经进入个性化 Deep Research；MyScholarQA 则发现合成用户与 LLM judge 会漏掉真人指出的细微错误。[\[3\]\[17\]\[20\]](#) PDR-Bench 的 P-Score 已按 task/persona 生成权重与子标准，因此不能把它描述成只看长度或文风。

因此，缺少的不是“更多 persona”“agent 会不会用 memory”或“persona-aware rubric”，而是在单用户绝对适配之上加入跨用户检验：固定任务、证据、工具和预算，只交换两个都合理的用户；让两套用户 rubric 交叉评价两份交付物，并用预冻结 must-change / must-hold / must-not 真值检查该变与不该变的部分。

因此我们采用反事实对照：固定任务、证据、工具和预算，只改变用户；再把两个用户的交付物交换评分。只有 matched 持续优于 swapped，同时事实和共同质量不下降，才支持“交付物对目标用户具有反事实特异性”。这不证明模型内部真正理解了用户；还需让同一 user-state 以 persona、自然历史、澄清对话和去关键词改写表达，检查核心结论是否稳定。不同 persona cue 会改变测量结论，[\[21\]](#) 个性化 rubric 也应同时检查代表性、一致性和区分力。[\[22\]](#)

### 两个月交付范围

| 项目           | 锁定规模                  |
|--------------|-----------------------|
| Task family  | 24 个                  |
| 核心 user-task | 48 个，两个强对比用户          |
| 用户信息条件       | 4 种                   |
| 核心 agent     | 3 类                   |
| 核心运行         | 最多 576 episodes       |
| 压力测试         | 8 个 anchor family     |
| JudgeBench   | 240 个判分单元             |
| 人评           | 至少 20% 输出；专家评事实，目标用户评 |

| 项目 | 锁定规模                    |
|----|-------------------------|
|    | matched/swapped；加关键失败仲裁 |

## DeepAlign-Bench：一张图讲完评测流程

## DeepAlign-Bench：长程 Deep Research 个性化交付物评测

五平面 Atlas × 跨用户 2×2 交叉评分 × 跨 cue 稳健性 × 行为测试算子



核心结果识别问题

同一任务 T、证据 E 下，哪份交付物更适合哪位用户？该结论能否跨语义等价 cue 保持，并不牺牲事实性、任务质量与隐私？

## ① Evaluation Atlas 元数据

A/B · Task + Environment

- stratum · intent · deliverable · demand
- evidence · freshness · tools · budget

C/D · User State + Signal


目标 · 知识 · 约束 · 风险 · 受众 · 权限  
brief · persona · clarification · history  
behavior · workspace · feedback · update  
每条事实带 provenance、时间、置信度与敏感级别

E · Agent System + Test Operator

search · memory · planning · orchestration  
Acquire · Preserve · Use · Update/Recover

## ② 反事实 2×2 + Cue 对照

24 families · 48 user-task · 4 signal modes



主矩阵 Ua/Ub; anchor 才加入 Uc/U0

$$Y_a = A(T, E, S_a) \quad Y_b = A(T, E, S_b)$$

再将  $Y_a/Y_b$  交换给 Ua/Ub 评分

跨用户对角优势 + 表达稳健性

$M_{aa} + M_{bb} > M_{ab} + M_{ba}$ ; must-hold 不下降  
同一 user-state 换 persona/history/clarification 仍稳定

## ③ 预注册可比运行

商业 Deep Research · 统一搜索 Harness

可复现开源 Deep Research Agent

Anchor probes: Code · Multi-agent · Memory

轨迹检查点



保存轨迹、交付物、版本、成本与时间戳

## ④ Rubric Compiler + JudgeBench

L0 确定性 verifier

文件、测试、格式、预算、权限与硬约束

L1 证据 verifier

claim 支持、引用覆盖、关联与来源质量

L2 元数据驱动 rubric judge

core + intent + deliverable + operator + risk

L3 强 Judge + 20% 人评

分层复核与分歧仲裁; SFT 仅可选附录

JudgeBench 竞争式选型

240 units · 人类金标 · 偏差/诱饵 · 模块校准

主榜规则：先过共同质量门槛，再比较个性化；禁止“迎合换分”

TQ / FR

任务质量 · 事实与引用

PF — MP

用户适配 · 误用惩罚

CFA / Cue Robustness

对角优势 · 语义等价稳定

Retention / Recovery

衰减曲线 · 恢复收益

Privacy / Calibration

隐私边界 · 推断校准

Coverage: Atlas × Operator × Agent

tested / defined-only / N/A / deferred + 95% CI

核心创新：Evaluation Atlas · Cross-user Matrix · Cue Equivalence · Rubric Compiler · JudgeBench

图1 固定任务与证据，只改变用户；先过共同质量门槛，再用 matched/swapped 识别结果特异性。

## 1. 论文要测的对象

一个 case 由五组元数据定义：

1. **Research Task**：使用情境、研究意图、领域、交付物和任务强度；
2. **Research Environment**：证据、时效、工具、预算和权限；
3. **User State**：目标、知识、约束、偏好、风险、受众和动态状态；
4. **Signal Channel**：persona、对话、澄清、历史、行为、工作区和反馈；
5. **Agent System**：模型版本、搜索、记忆、规划、多 agent 和工具。

这五组信息组成 Evaluation Atlas。它定义完整可测试空间，但不承诺首版跑完所有组合。

### 四种行为测试

- Acquire：缺信息时会不会正确澄清；
- Preserve：长任务和交接后会不会忘记；
- Use：是否把用户信息落实到结果；
- Update/Recover：用户纠正后能否更新和恢复。

## 2. Task 和 Persona 怎么构建

### Task 覆盖

任务采用 使用情境 × 研究意图 × 任务强度：

- 使用情境：个人日常、专业企业、学术前沿；
- 研究意图：理解、发现、决策、预测、规划、审计；
- 任务强度：概念广度、逻辑层数、探索性、搜索 fan-out、时效和风险。

18 个 family 覆盖 3×6 主单元，6 个 family 复测关键单元，共 24 个。

### Persona 原则

Persona 不是人物小传，而是 task-conditioned user state 的一种展示。每组 persona-task 必须通过六项检查：场景真实、会影响决策、用户间可区分、存在共同核心、信息最少且隐私可控、不依赖刻板印象。

每个 user-task 都在运行前建立真值包：共同要求、用户特异要求、禁止事项、可接受替代、关键证据、严重错误封顶、预期澄清点、matched/swapped 的差异预测。

3. 核心实验

```
24 task families × 2 users × 4 signal conditions × 3 agents
= 最多 576 core episodes
```

四种信号条件：task-only、structured persona、语义等价自然历史、clarification-allowed。

三类核心 agent：商业 Deep Research、统一搜索/工具 harness、可复现开源 Deep Research。

8 个 anchor family 是压力测试宿主，不是 8 种 persona。流程是：先让两个用户都与 task 合理匹配，建立 clean matched/swapped 真值；再固定目标用户、task、证据和预算，只改变可见 persona、上下文位置、交接摘要或更新时间。

所有 anchor 都有 clean + persona swap + irrelevant-signal 配对；冲突/过期、context dilution、agent handoff、动态更新按预注册适用性分配。Re-anchor 是恢复干预，不是攻击类型；固定子集无论是否先失败都重跑，避免高估恢复收益。

指标：ΔPF / invariance、冲突解析率、PF retention/AUC、handoff loss、update correctness、recovery gain；同时报告 TQ、事实性、隐私和长度副作用。

Frozen Core、Live Web、Longitudinal 三条轨道分开报告；不同工具预算和不可复现产品不混成一个榜。

4. Rubric 和 Metrics

Metadata-driven Rubric Compiler

```
Core + Personalization + Intent + Deliverable + Operator + Risk
→ 当前 case 的 rubric
```

统一的是 rubric 叶节点格式、适用条件和校准程序，不是让报告、代码、表格和幻灯共享同一张评分表。

四类评价契约

- Must change：不同用户必须变化；
- Must hold：共同事实和质量必须保持；
- Must not：不得假设、泄露或越权；
- Clarify if unknown：缺关键信息时应提问或给条件分支。

主指标

| 指标      | 回答的问题                  |
|---------|------------------------|
| TQ / FR | 任务和事实是否先过基本质量门槛        |
| PF - MP | 用户特异要求减去误用、泄露和过度迎合     |
| CFA     | matched 是否稳定优于 swapped |

| 指标                       | 回答的问题                   |
|--------------------------|-------------------------|
|                          |                         |
| Worst-view CFA / Cue Gap | 同一 user-state 换表达后是否仍稳定 |
| Retention                | 长任务中用户适配保留多少            |
| Recovery                 | 纠正或重新锚定后恢复多少            |

主榜先过 TQ、FR 和关键隐私门槛，再报告个性化指标。不能用“懂用户”补偿事实错误。

5. Judge 方案

```
L0 确定性 verifier
→ L1 证据 verifier
→ L2 强通用 rubric judge
→ L3 目标用户/领域专家复核
```

JudgeBench 用 240 个单元测试位置偏差、长度偏差、漂亮格式诱饵、persona 关键词堆叠、隐私泄露、边界答案和正确弃权。

两个月主线：`verifier` → `strong judge` → 20% 分层人评 + 分歧仲裁。

SFT scorer 只在第 4 周前已有高质量 gold 且不阻塞主实验时进入附录。“人工 0/1 + GPT reason”不能直接当新真值，必须加入 evidence span、错误类型、置信度和弃权。

6. 最终交付物是否足够

主榜：足够

最终交付物可以判断：结果是否适合用户、matched 是否优于 swapped、是否损害事实性、是否泄露或过度迎合。

机制结论：不够

只看最后报告无法区分“没读到、忘了、知道但没用”。因此全量保存轻量轨迹，20%-30% 子集做 memory、handoff 和 re-anchor 的受控重跑。

如果诊断子集没有完成，论文只主张“最终交付物个性化”，不主张已经定位内部偏移时刻。

7. 预期论文贡献

- 1. **Evaluation Atlas**：机器可读地描述 task、environment、user state、signal 和 agent；

- 2. **Counterfactual families**：用 matched/swapped 构造跨用户 2×2 对角优势，并用语义等价信号检查表面 cue 敏感性；
- 3. **Failure taxonomy**：任务类型负责覆盖，结果风险和失败模式负责诊断；
- 4. **Rubric compiler**：根据元数据选择可适用模块；
- 5. **JudgeBench**：先证明评委可靠，再发布自动榜单；
- 6. 可复现协议：coverage manifest、版本、预算、轨迹和评分均可审计。

与 PDR-Bench 的关键差异

差异不能写成“更多任务和更多 agent”，也不能说 PDR-Bench 没有 persona-aware rubric。真正差异是：在其单用户绝对适配之上增加跨用户 matched/swapped 对角优势、预冻结变化/不变项和跨线索表达稳健性；再用动态/长程测试与独立 JudgeBench 诊断失败。

8. 两个月安排

| 周 | 研究产出                                 | Go / No-Go          |
|---|--------------------------------------|---------------------|
| 1 | Atlas、schema、coverage、24 family 配额   | ontology 是否可运行      |
| 2 | 24 family、48 user state、persona 检查   | 80% family 有稳定用户差异  |
| 3 | 真值包和 rubric modules                  | matched/swapped 可区分 |
| 4 | 240-unit JudgeBench、6 family dry run | judge 不过门则扩大人评      |
| 5 | 三类核心 agent 主矩阵                       | 成本和失败率可控            |
| 6 | anchor 压测、20% 人评、错误编码                | 是否有独立个性化信号          |
| 7 | 统计、覆盖审计、Results 初稿                   | 删除不受支持支线            |
| 8 | 结果冻结、复现、全文和匿名材料                      | 不再新增分类和系统           |

9. 需要导师拍板

- 1. 是否同意 Atlas、跨用户反事实特异性和 rubric compiler 是核心贡献，而不是“测尽所有组合”？

2. 是否锁定 24 family、48 user-task、4 条件、3 类 agent 的主矩阵？
3. 是否同意 SFT scorer 不阻塞主论文？
4. 是否同意代码、多 agent、memory 和动态用户只进入 8 个 anchor family？
5. 若 judge 或 persona 真值不过门，是否接受缩小论文主张，而不是继续扩大数据？

## 10. 最重要的风险

- Persona 如果只是作者想象，个性化 gold 不成立；
- Rubric 如果不能区分 matched/swapped，CFA 没有意义；
- Judge 如果偏爱长度和风格，自动榜单不可信；
- 元数据很多但测试稀疏，必须公开 coverage 缺口；
- 不同 agent 工具和预算不同，必须分轨道比较；
- 两个月最大的风险不是任务少，而是范围继续扩大导致没有完整主实验。

## 参考文献

- [1] OpenCompass Team. *OpenCompass: A Universal Evaluation Platform for Large Language Models*. 2026.
- [2] Zhang et al. *Agent-SafetyBench*. arXiv:2412.14470.
- [3] *Towards Personalized Deep Research: Benchmarks and Evaluations*. arXiv:2509.25106.
- [4] Wang et al. *LiveResearchBench*. arXiv:2510.14240.
- [5] Sharma et al. *ResearchRubrics*. arXiv:2511.07685.
- [6] Liang et al. *HELM*. TMLR, 2023.
- [7] Ribeiro et al. *CheckList*. ACL, 2020.
- [8] Reuel et al. *BetterBench*. arXiv:2411.12990.
- [9] Zeng et al. *Setoka*. arXiv:2607.27056.
- [10] Qian et al. *User-Conditioned Evaluation under Temporal Interventions*. arXiv:2607.21635.
- [11] Yang et al. *PersonaTrail*. arXiv:2607.20482.
- [12] Todisco et al. *TARS*. arXiv:2607.15948.
- [13] Yang. *SARSI Agents for Personal Singularity*. arXiv:2607.12254.
- [14] Mao et al. *Agents Don't Just Agree, They Remember*. arXiv:2607.10526.
- [15] Yang et al. *APeB*. arXiv:2607.03162.
- [16] Hao et al. *Evaluating Personalized Tool-Augmented LLMs from the Perspectives of Personalization and Proactivity*. ACL, 2025. <https://aclanthology.org/2025.acl-long.1064/>
- [17] Li et al. *Personalized Deep Research: A User-Centric Framework, Dataset, and Hybrid Evaluation*. arXiv:2605.10530.
- [18] Liang et al. *Learning Personalized Agents from Human Feedback*. arXiv:2602.16173.
- [19] Shen et al. *Mem2ActBench*. ACL, 2026. <https://aclanthology.org/2026.acl-long.370/>
- [20] Balepur et al. *Language Models Don't Know What You Want*. ACL, 2026. <https://aclanthology.org/2026.acl-long.723/>
- [21] Weeber et al. *One Persona, Many Cues, Different Results*. ACL, 2026. <https://aclanthology.org/2026.acl-long.2079/>
- [22] Qiu et al. *Preference-Aware Rubric Learning for Personalized Evaluation*. arXiv:2605.31545, 2026. <https://arxiv.org/abs/2605.31545>